

Uniwersytet Warszawski
Wydział Nauk Ekonomicznych

Stanisław Drąg
Nr albumu: 463337

**Analiza czynników determinujących ceny
przejazdów Ubera i tradycyjnych taksówek –
porównanie na przykładzie Nowego Jorku**

Praca licencjacka
na kierunku: Informatyka i Ekonometria

Praca wykonana pod kierunkiem
dr Krzysztofa Gyódiego
z Katedry Ekonomii Cyfrowej
WNE UW

Warszawa, czerwiec 2026

Oświadczenia kierującego pracą

Oświadczam, że niniejsza praca została przygotowana pod moim kierunkiem i stwierdzam, że spełnia ona warunki do przedstawienia jej w postępowaniu o nadanie tytułu zawodowego.

Data

Podpis kierującego pracą

Oświadczenie autora pracy

Świadom odpowiedzialności prawnej oświadczam, że niniejsza praca dyplomowa została napisana przeze mnie samodzielnie i nie zawiera treści uzyskanych w sposób niezgodny z obowiązującymi przepisami.

Oświadczam również, że przedstawiona praca nie była wcześniej przedmiotem procedur związanych z uzyskaniem tytułu zawodowego w wyższej uczelni.

Oświadczam ponadto, że niniejsza wersja pracy jest identyczna z załączoną wersją elektroniczną.

21.05.2026 r.

Data

Stanisław Drąg

Podpis autora pracy

Oświadczenie o wykorzystaniu w pracy systemów sztucznej inteligencji (SI)

Podczas przygotowania tej pracy autor używał ChatGPT w celu usprawnienia procesu pisania pracy poprzez pomoc w wyszukiwaniu i analizowaniu artykułów naukowych, pisaniu skryptów, formatowaniu bibliografii i sprawdzaniu zgodności pracy z wytycznymi. Autor pracy dokonał weryfikacji treści i redakcji tekstu pracy zgodnie z jej założeniami, prezentując własny wkład intelektualny i bierze pełną odpowiedzialność za ostateczną postać pracy.

.....Stanisław Drąg
Podpis Autora / Autorów

Streszczenie

Platformy, takie jak Uber, stały się nieodłącznym elementem systemu transportowego w wielu miejscach na świecie, w dużej mierze zastępując tradycyjne taksówki. Jednym z głównych czynników odróżniających model działania Ubera od taxi jest elastyczność, zwłaszcza na poziomie podaży i cenowym. Została ona osiągnięta dzięki dedykowanemu algorytmowi reagującemu w czasie rzeczywistym na warunki na rynku. Różnice między platformami a klasycznymi taksówkami stwarzają nowe wyzwania wszystkich stron rynku: pasażerów, kierowców, firm i decydentów.

Słowa kluczowe

Uber, taxi, determinanta, cena, platforma, elastyczność cenowa, przejazdy na aplikację

Dziedzina pracy (kody wg programu Erasmus)

Ekonomia (14300)

Klasyfikacja tematyczna

Tytuł pracy w języku angielskim

Analysis of Factors Determining Uber and Traditional Taxi Pricing: A Comparison based on New York City

SPIS TREŚCI

WSTĘP.....	5
ROZDZIAŁ I. <Teoria i przegląd literatury>.....	7
1.1. <Taxi w Nowym Jorku>	7
1.1.1. <Rys historyczny>.....	7
1.1.2. <Funkcjonowanie>.....	8
1.2. <Uber>.....	10
1.2.1. <Historia>	10
1.2.2. <Model działania>	10
1.2.3. <Algorytm cenowy>	11
1.3. <Platformy>.....	12
1.3.1. <Wprowadzenie>	12
1.3.2. <Definicja>	13
1.3.3. <Mechanizmy ekonomiczne>	13
1.3.4. <Uber jako platforma>	14
1.3.5. <Wpływ Ubera na sektor taxi>	15
1.4. <Hedoniczne modele cen>.....	15
1.5. <Determinanty cen przejazdów Ubera – badania empiryczne>.....	16
1.6. <Hipotezy i pytania badawcze>.....	18
1.6.1. <Pytania badawcze>	18
1.6.2. <Hipotezy badawcze>	18
ROZDZIAŁ II. <Analiza empiryczna>.....	21
2.1. <Opis bazy danych>.....	21
2.2. <Analiza eksploracyjna>	23
2.3. <Model ekonometryczny>	29
2.3.1. <Specyfikacja>	29
2.3.2. <Diagnostyka>	30
2.3.3. <Wyniki estymacji>.....	31
2.3.4. <Weryfikacja hipotez badawczych>.....	36
ZAKOŃCZENIE	39
BIBLIOGRAFIA	41
ZESTAWIENIE SPISÓW.....	45
ZAŁĄCZNIKI	47

WSTĘP

Platformy, takie jak Uber, stały się nieodłącznym elementem systemu transportowego w wielu miejscach na świecie, w dużej mierze zastępując tradycyjne taksówki (Lee et al., 2018; Nie, 2017).

Jednym z głównych czynników odróżniających model działania Ubera od taxi jest elastyczność, zwłaszcza na poziomie podażowym i cenowym. Została ona osiągnięta dzięki dedykowanemu algorytmowi reagującemu w czasie rzeczywistym na warunki na rynku poprzez *surge-pricing*, czyli zwiększanie ceny w okresach nadwyżki popytu (Gurley, 2014). Ta elastyczność prowadzi do większej efektywności Ubera w stosunku do taxi (Cramer i Krueger, 2016).

Tym niemniej, jak zauważyli Battifarano i Qian (2019), duża część badań nad *surge-pricingiem* skupia się na aspekcie teoretycznym – jego wpływie na zachowanie kierowców, modelowaniu przy pomocy teorii gier czy analizie równowagi rynkowej. Stosunkowo mało jest natomiast badań empirycznych, które analizowałyby kształtowanie się cen w zależności od różnych zmiennych. I choć od czasu opublikowania ich artykułu minęło ponad 6 lat, a w przeciągu tego czasu ukazało się więcej artykułów adresujących tę lukę badawczą, to wciąż nie została ona zupełnie wypełniona.

Celem tej pracy jest analiza czynników determinujących ceny przejazdów Ubera i tradycyjnych taksówek. Jej podstawą są raporty publikowane co miesiąc przez NYC Taxi and Limousine Commission (TLC), zawierające mikrodane na poziomie pojedynczych przejazdów. W oparciu o nie przeanalizowany zostanie wpływ cech, takich jak dystans, czas, pora dnia, dzień tygodnia czy weekend, na cenę przejazdów Ubera i tradycyjnych żółtych taksówek na Manhattanie w Nowym Jorku. Wykorzystany zostanie w tym celu model regresji liniowej, estymowany klasyczną metodą najmniejszych kwadratów, a także metody statystyczne, takie jak korelacje czy charakterystyki opisowe.

Temat ten jest istotny, gdyż uzyskanie wiedzy na temat wpływu zmiennych, takich jak dystans, czas, pora dnia, dzień tygodnia czy weekend, na ceny, mogłoby w znaczący sposób przyczynić się do poprawy sytuacji wszystkich uczestników rynku. Mając tę wiedzę, pasażerowie mogliby efektywniej planować swoje podróże, unikając niepotrzebnych kosztów. Analiza wspiera również kierowców, którzy z jej pomocą mogliby maksymalizować swoje zyski, wykorzystując okresy zwiększonego popytu oraz oceniając koszty alternatywne zmiany lokalizacji. Przewoźnicy z kolei mogliby wykorzystać wyciągnięte z analizy wnioski aby efektywniej zarządzać podażą oraz popytem (np. poprzez wprowadzanie w określonych

porach bonusów dla kierowców i / lub promocji dla pasażerów). Uzyskane wyniki mogą być także wartościowe dla polityków i decydentów, którzy mogliby dzięki nim lepiej dostosowywać użycie środków transportu publicznego (np. poprzez zróżnicowanie ilości kursujących autobusów w zależności od czasu i lokalizacji). Aspekty te, w szczególności ostatni, mogą być szczególnie przydatne na rynkach, gdzie sytuacja dynamicznie się zmienia – choćby na rynku warszawskim, gdzie w ostatnich latach nastąpił ogromny wzrost popularności platform oferujących przejazdy na zamówienie (Miasto Warszawa, 2026).

Struktura pracy wygląda następująco: po niniejszym wstępie następuje część teoretyczna, w tym krótki rys historyczny i opis modelu działania tradycyjnych nowojorskich taksówek oraz Ubera, krótkie przedstawienie literatury na temat platform, przegląd prac empirycznych dotyczących Ubera i taxi oraz omówienie hipotez i pytań badawczych. Następnie w części empirycznej opisany zostaje zbiór danych, przedstawione zostają statystyki opisowe oraz wyniki modelu ekonometrycznego. Na tej podstawie następuje weryfikacja hipotez, zaś na końcu wszystko zostaje zebrane w ramach zakończenia.

ROZDZIAŁ I

Teoria i przegląd literatury

1.1. Taxi w Nowym Jorku

1.1.1. Rys historyczny

Początki rynku taksówkarskiego w Nowym Jorku sięgają roku 1907. Wówczas to przedsiębiorca Harry N. Allen sprowadził 65 taksówek z Francji, gdzie były już one bardzo popularne. Od tego momentu taksówki zaczęły stopniowo wypierać używane dotychczas powozy konne (*NYC TLC*, 2025).

Do 1935 r. rynek taksówkarski w Nowym Jorku był nieuregulowany, a składał się z walczących o dominację flot. Sytuacja zmieniła się podczas Wielkiego Kryzysu. Bieda sprawiła, że wielu nowojorczyków decydowało się na wybór tańszych środków transportu, a w konsekwencji popyt na usługi taxi znacząco spadł. Spadek ten zmusił wiele firm do wyjścia z rynku, a także przyczynił się do utraty pracy wielu taksówkarzy. Sytuację dodatkowo pogarszali oportuniści stosujący praktyki określane jako podstępne lub wręcz nieuczciwe, takie jak drastyczne obniżanie cen w celu przejęcia klientów (*NYC TLC*, 2025).

Frustracja taksówkarzy przerodziła się w burzliwe protesty i żądania regulacji dla sektora. Rada Aldermanów (poprzednik obecnej Rady Miasta) odpowiedziała na protesty, uchwalając w 1937 roku „*Haas Act*”, który wprowadził system medalionów (licencji) używany do dzisiaj. Zgodnie z treścią aktu, liczba medalionów, a co za tym idzie taksówek, została ograniczona do tej, która była w owej chwili w użyciu. Dalsza jej redukcja nastąpiła w sposób naturalny, doprowadzając do zrównania podaży z popytem, stabilizując agresywną konkurencję o klientów.

Branża taksówkarska rozkwitła ponownie podczas drugiej wojny światowej. Ze względu na ograniczoną podaż paliwa i części samochodowych, ludzie powrócili do używania taksówek jako głównego środka transportu. W międzyczasie drastycznie wzrosły ceny medalionów, gdyż ich właściciele zorientowali się, że jest to aktywum, którym można handlować. W ten sposób ceny medalionów wzrosły z 10\$ w 1937 r. do 5000\$ w 1950 r. (*NYC TLC*, 2025).

Kolejne problemy pojawiły się w roku 1960. Pierwszym był wzrost liczby zgłaszanych przypadków tzw. „dyskryminacji klienta”, polegającej na tym, że kierowcy selekcjonowali pasażerów, których przyjmowali (co wynikało prawdopodobnie głównie ze względów

bezpieczeństwa). Sytuacja ta doprowadziła do wzrostu popytu na „lewe taksówki” (ang. *gypsy cabs*), co szybko doprowadziło do nieporozumień, jako że pasażerowie nie wiedzieli czy taksówka jest licencjonowana, czy też „lewa” (NYC TLC, 2025).

Aby uniknąć tych nieporozumień, prawodawcy Nowego Jorku zdecydowali, że wszystkie „medalionowe” taksówki powinny być żółte. W 1971 r., na mocy „*Local Law 12*”, powołano Nowojorską Komisję ds. Taksówek i Limuzyn (ang. *Taxi and Limousine Commission, TLC*), której zadaniem było, i jest do dzisiaj, regulowanie rynku taksówkarskiego w Nowym Jorku. Komisja odpowiada w szczególności za licencjonowanie kierowców i pojazdów, regulowanie zasad funkcjonowania rynku oraz egzekwowanie przepisów dotyczących bezpieczeństwa i jakości usług transportowych. Te zmiany doprowadziły do bardziej konsekwentnej regulacji taksówek „medalionowych”, jednocześnie legitymizując „lewe taksówki”, które przekształciły się z czasem w pojazdy na zamówienie (ang. *for-hire vehicles*). I choć w kolejnych latach sektor *for-hire* ewoluował, a poszczególne podgrupy celowały w konkretne grupy klientów, to do dziś żółte taksówki jako jedyne mają prawo do zabierania pasażerów bezpośrednio z ulicy (ang. *street hail*) (NYC TLC, 2025).

1.1.2. Funkcjonowanie

Obecnie sektor taksówkarski w Nowym Jorku obejmuje kilka różnych segmentów. Oprócz klasycznych żółtych taksówek (ang. *yellow cabs*), które mogą zabierać pasażerów bezpośrednio z ulicy, funkcjonują także m.in. taksówki zielone (ang. *green taxis*) oraz pojazdy typu *for-hire vehicle*, które mogą realizować przejazdy wyłącznie po wcześniejszym zamówieniu przez aplikację lub telefon. Szczególną kategorią tych ostatnich są pojazdy typu *high volume for-hire vehicles (HVFHV)*, do których zaliczane są te świadczące usługi dla firm wykonujących ponad 10 000 przejazdów dziennie. Obecnie w Nowym Jorku są to *Uber* oraz *Lyft*. Wszystkie pojazdy używane do świadczenia usług taksówkarskich, niezależnie od segmentu, muszą przejść kompleksową kontrolę bezpieczeństwa i emisji przeprowadzaną przez TLC, a wszyscy kierowcy muszą posiadać aktywną licencję oraz przejść weryfikację (ang. *background check*), a także spełnić określone wymagania edukacyjne (NYC TLC, 2025).

Według corocznego raportu TLC za rok 2025, opublikowanego w styczniu 2026 r., na koniec 2025 r. było 180 169 licencjonowanych kierowców. Licencje te pozwalają kierowcom na prowadzenie pojazdów z każdego segmentu rynku, zarówno żółtych taksówek, jak i *for-hire vehicles*. Aby otrzymać licencję, należy m.in. przejść test na obecność narkotyków, oddać

odciski palców, a także ukończyć kurs jazdy defensywnej oraz kurs edukacyjny. Z kolei jeśli chodzi o pojazdy, to na koniec 2025 r. licencjonowanych było ponad 118 000 samochodów, w tym 13 589 żółtych taksówek oraz 82 225 pojazdów związanych z *HVFHS* (*NYC TLC*, 2025). Choć wymagania licencyjne dla kierowców są jednolite dla wszystkich segmentów rynku, to elementem różnicującym segment żółtych taksówek od pozostałych są medaliony (wprowadzone w 1937 r. przez „*Haas Act*” (patrz 1.1.1.)), czyli specjalne licencje, których posiadanie uprawnia pojazdy typu żółte taksówki, i tylko je, do zabierania pasażerów prosto z ulicy, bez wcześniejszego zamawiania przejazdu.

Jeśli chodzi o ceny, to taryfy żółtych taksówek są ściśle określone i regulowane przez *TLC*, a składają się na nie: opłata początkowa w wysokości 3\$, opłata odpowiednio za dystans lub czas (w zależności od prędkości jazdy – 70 centów za 0,2 mili przy jeździe z prędkością ponad 12 mil na godzinę lub 70 centów za 60 sekund przy jeździe wolniejszej lub staniu w korku) oraz opłaty dodatkowe – 50 centów *MTA State Surcharge*, 1\$ *Improvement Surcharge*, 1\$ opłaty nocnej w godzinach od 20 do 6, 2,5\$ opłaty „godzino-szczytowej” w godzinach od 16 do 20 w dni robocze (oprócz świąt), 2,5\$ *New York State Congestion Surcharge* jeśli trasa przejazdu prowadziła przez Manhattan na południe od *96th Street*, oraz 75 centów *MTA Congestion Pricing* w odpowiednim obszarze. Natomiast ceny *HVFHV* określane są przez firmy, na podstawie ich algorytmów cenowych, aczkolwiek tutaj również występują opłaty dodatkowe narzucone przez prawo, takie jak choćby podatki (*NYC TLC*, 2025).

Tabela 1. Składowe opłaty końcowej obliczanej na podstawie taryfy taxi NYC

Rodzaj opłaty	Kwota
Opłata początkowa (flag drop)	3,00 \$
Opłata za dystans (0,2 mili, >12 mph)	0,70 \$
Opłata za czas (60 sek., ≤12 mph lub postój)	0,70 \$
MTA State Surcharge	0,50 \$
Improvement Surcharge	1,00 \$
Opłata nocna (20:00–6:00)	1,00 \$
Opłata w godzinach szczytu (16:00–20:00, dni robocze)	2,50 \$
New York State Congestion Surcharge (Manhattan <96th St)	2,50 \$
MTA Congestion Pricing (wybrany obszar)	0,75 \$

Źródło: Opracowanie własne na podstawie: <https://www.nyc.gov/site/tlc/passengers/taxi-fare.page>

1.2. Uber

1.2.1. Historia

Uber Technologies Inc. to amerykańskie przedsiębiorstwo z siedzibą w San Francisco w stanie Kalifornia. Stworzyło m.in. aplikację mobilną Uber, służącą do zamawiania usług transportu samochodowego poprzez łączenie pasażerów z kierowcami. Historia Ubera zaczęła się w 2008 r., kiedy Travis Kalanick i Garrett Camp, biorący udział w konferencji w Paryżu, mieli problem ze złapaniem taksówki podczas mroźnej zimowej nocy. Wpadli oni wówczas na pomysł stworzenia aplikacji, która pozwalałaby pasażerom na zamówienie pojazdu na żądanie. Ich firma powstała w 2009 r., a w 2010 r. rozpoczęła pełnoskalową działalność w San Francisco. Początkowo Uber używał jedynie pojazdów Lincoln Town Cars i współpracował z kierowcami taksówek do ich prowadzenia. W miarę zyskiwania popularności firma rozszerzała swoją działalność. W 2011 r. zaczęła świadczyć usługi w Nowym Jorku oraz Paryżu, a w 2013 r. nastąpiła ekspansja na rynek chiński i indyjski. W 2012 r. firma wprowadziła usługę UberX, która opierała się na zwykłych samochodach, prowadzonych przez nieprofesjonalnych kierowców. Ta usługa szybko zyskała na popularności i obecnie jest jedną z podstaw działalności Ubera (Uber, 2018; Garcia, 2024). Dane z raportów TLC wskazują na istotną transformację rynku przewozów w Nowym Jorku po 2012 roku. Podczas gdy liczba żółtych taksówek pozostawała względnie stabilna (ok. 13,5 tys., co wynika z regulowanego systemu medalionów), liczba pojazdów typu *for-hire vehicles* wzrosła z ok. 47 tys. w 2013 r. do ponad 80 tys. w 2016 r. Wtedy też ujednolicone zostały licencje dla kierowców, czyli jedna licencja uprawniała do prowadzenia zarówno żółtych taksówek, jak i *fhv* (NYC TLC, 2016). W 2018 r. liczba *for-hire vehicles* wzrosła do 120 tys. Wówczas też wprowadzona została nowa kategoria – *high-volume for-hire services (HVFHS)*, czyli platform takich jak Uber, realizujących ponad 10 tys. kursów dziennie. Obecnie liczba *for-hire vehicles* wynosi ponad 118 tys., w tym 82 225 pojazdów związanych z *HVFHS*. Szczególnie istotna jest zmiana struktury tego segmentu *fhv*, która dokonała się na przestrzeni ostatnich lat, w wyniku której pojazdy *HVFHS* stały się dominującą częścią rynku (stosunek ilości tych pojazdów do żółtych taksówek wynosi ok. 6:1).

1.2.2. Model działania

Uber nie zatrudnia kierowców bezpośrednio, ale działa jako platforma cyfrowa, oferując usługę polegającą na łączeniu pasażerów z kierowcami w czasie rzeczywistym lub z

wyprzedzeniem poprzez aplikację lub stronę internetową. Kierowcy nie są pracownikami, a niezależnymi kontraktorami, samozatrudnionymi lub zatrudnionymi przez właścicieli flot. Podejmują oni decyzje o tym kiedy pracować, jakie przyjmować zlecenia itd. niezależnie od Ubera. Co więcej, kierowcy ci nie muszą wcale być kierowcami zawodowymi. Wielu z nich traktuje tę pracę jako dorywczą, służącą jako dodatkowe źródło dochodu (Abraham, 2024). Również pojazdy nie muszą służyć wyłącznie do celów przewozowych, a większość kierowców używa aut prywatnych. Prowadzi to do licznych tarć z sektorem taksówek tradycyjnych, uważających taki sposób postępowania za nieuczciwy względem nich, co często kończy się koniecznością interwencji organów rządzących (Gurley, 2014; Chen et al., 2015). Rozwój Ubera wpisuje się w szerszy trend tzw. gospodarki współdzielenia (ang. *sharing economy*) oraz pracy platformowej (ang. *gig economy*) (Abraham, 2024; Pepić, 2018). Z perspektywy rynku pracy działalność na platformach takich jak Uber często ma charakter elastyczny i stanowi uzupełnienie dla głównego źródła dochodu (Abraham, 2024). Mimo to, w przypadku Ubera występuje również profesjonalizacja. Dla części kierowców jest to główne lub nawet jedyne źródło dochodu, i w tych przypadkach od strony pracownika sytuacja w segmencie Ubera jest bardzo zbliżona do segmentu taxi. Warto również zauważyć, że choć Uber korzystał z trendów ekonomii współdzielenia, to głównym jego celem w tym aspekcie nie była wiara w tę politykę, a chęć ocieplenia wizerunku (Meelen i Frenken, 2015).

1.2.3. Algorytm cenowy

Model biznesowy platformy opiera się natomiast na pobieraniu prowizji od każdej transakcji wynikającej z realizacji przejazdu. Ceny przejazdów są natomiast ustalane przez algorytm, co jest kolejnym elementem odróżniającym Ubera od tradycyjnych taksówek, które pobierają opłaty zgodnie z uregulowaną przez prawo taryfą. Algorytm Ubera nie jest jawny, wiadomo jednak, że uwzględnia m.in. czas przejazdu, dystans czy korki. Jednak jego kluczowym elementem, odróżniającym go od taryfy taxi, jest tzw. *surge-pricing*, czyli mnożnik ceny. Dzięki niemu ceny przejazdów ustalane przez Ubera są dynamiczne i kształtują się w czasie rzeczywistym w odpowiedzi na popyt i podaż, w przeciwieństwie do sztywnych cen tradycyjnych taksówek. *Surge-pricing* jest stosowany, gdy popyt znacznie przewyższa podaż. Jego genezą jest sytuacja z Bostonu, z 2012 r. (Gurley, 2014). Wówczas to pracownicy Ubera stanęli naprzeciw problemowi – zaobserwowali oni, że w piątkowe oraz sobotnie noce, około godziny 1, występował drastyczny wzrost „niezrealizowanych żądań”, czyli sytuacji, w których pasażer zamawiał przejazd, jednak nie był on realizowany.

Przyczyną tego zjawiska było to, że w tym czasie kierowcy kończyli pracę, a równocześnie bardzo wiele osób chciało skorzystać z ich usług po imprezach i innych nocnych aktywnościach. Powodowało to mocną dysproporcję popytu i podaży, prowadzącą do tych właśnie niezrealizowanych przejazdów. Bostoński oddział Ubera jako rozwiązanie wprowadził wyższe ceny w okresach, w których wykryto problem. W efekcie podaż kierowców zwiększyła się o ok. 70%, a liczba niezrealizowanych zamówień spadła o 66%. Bazując na tym doświadczeniu, Uber wprowadził mechanizm *surge-pricingu* na poziomie aplikacji. Jest on aplikowany automatycznie kiedy popyt znacznie przewyższa podaż, co jest mierzone za pomocą czasu oczekiwania i liczby niezrealizowanych żądań. Działanie tego mechanizmu jest dwukanałowe – z jednej strony motywuje on kierowców do wsiadania za kierownicę, jako że stawki są wyższe, a z drugiej redukuje popyt z tego samego powodu. Pozwala to na zrównanie się popytu i podaży, a w efekcie na maksymalizację liczby zrealizowanych zleceń oraz względnie szybki powrót ceny do normalnego poziomu (Binns et al., 2025; Hall et al., 2018; Chen et al., 2015; Gyódi, 2017; Gurley, 2014).

Warto zauważyć, że podobne procesy zachodzą w branżach hotelarskich czy lotniczych, gdzie również w momentach zwiększonego popytu ceny gwałtownie rosną. Różnica jest jednak taka, że w ich przypadku podaż jest względnie stała, zatem racjonalną reakcją jest drastyczne podniesienie ceny. Natomiast w przypadku Ubera podaż jest elastyczna, zatem spodziewać się można, że skala podniesienia ceny będzie dużo mniejsza, oraz że dużo szybciej wróci ona do normy. Jak podaje sam Uber, typowe okresy, w których występuje *surge-pricing* to piątkowe i sobotnie noce, „popracowe” godziny szczytu, a także specjalne wydarzenia czy święta (Uber, 2019; Gurley, 2014).

1.3. Platformy

1.3.1. Wprowadzenie

Warto w tym momencie spojrzeć na Ubera z szerszej perspektywy. Jest on bowiem jedynie jednym z licznych przykładów relatywnie nowego trendu, który rozwinął się na przestrzeni ostatnich lat. Mowa tu o platformach:

„Rewolucję spowodowały jednak dopiero te przedsiębiorstwa, które wypracowały nowe modele biznesowe oparte na postępującej internetyzacji, upowszechnieniu urządzeń mobilnych oraz lawinowo zwiększających się możliwościach zbierania i przetwarzania danych: platformy.”

1.3.2. Definicja

Platformy można analizować w ramach teorii rynków dwustronnych (ang. *two-sided markets*), w których przedsiębiorstwo pośredniczy między dwiema grupami użytkowników, a także rozszerzyć tę analizę na rynki wielostronne (ang. *multi-sided markets*). Według tych teorii, platformy są pośrednikami między różnymi stronami rynku (kupujący, sprzedający, dystrybutorzy, reklamodawcy itd.). Model ich działania opiera się na dostarczaniu wartości poprzez umożliwienie interakcji pomiędzy tymi stronami, a także ich dopasowywanie (Armstrong, 2006; Rochet i Tirole, 2006). Przykładem platformy może być Airbnb, pełniące rolę pośrednika między osobami chcącymi wynająć swój pokój czy mieszkanie (1 strona) i osobami chcącymi skorzystać z oferty wynajęcia (2 strona). Kluczowa jest tutaj owa wielostronność. Przykładem przedsiębiorstwa, które może być błędnie postrzegane jako platforma, jest Netflix. Jednak, jako że nie pełni on roli pośrednika między stronami rynku, a jedynie dostarcza usługi *streamingowe*, nie może być zaklasyfikowany jako platforma (Śledziwska i Włoch, 2020; Gyódi, 2017).

1.3.3. Mechanizmy ekonomiczne

Dzisiejsze platformy funkcjonują w oparciu o mechanizmy znane z tradycyjnej gospodarki oraz teorii ekonomicznej. Są to mechanizmy takie jak efekty sieciowe, korzyści skali, koszty krańcowe czy koszty transakcyjne, jednak model działania platform pozwala na znacznie intensywniejsze ich wykorzystanie (Evans i Schmalensee, 2016).

Efekty sieciowe polegają na tym, że im większa liczba uczestników sieci, tym bardziej użyteczne staje się uczestnictwo w niej. Wyróżnić można efekty sieciowe bezpośrednie oraz pośrednie. Bezpośrednie polegają na tym, że część korzyści (lub kosztów), wynikających z działań jednego członka sieci, przenosi się na innych jej członków. Przykładowo, kiedy do sieci dołączają kolejni uczestnicy, wszyscy pozostali odnoszą korzyści, ponieważ wzrasta zasięg sieci, a wraz z nim ogólna wartość uczestnictwa. Bezpośrednie efekty sieci nie oznaczają jednak automatycznie wielostronności, która jest istotą platform – występują choćby w sieciach telefonicznych, które są jednostronne. W przypadku platform występują jednak również efekty sieciowe pośrednie, i to one właśnie dają platformom przewagę

względem gospodarki tradycyjnej. Chodzi w nich o to, że jedna strona (np. kierowcy) zyskuje, gdy rośnie liczebność drugiej strony (np. pasażerów), i odwrotnie. Jest to zatem proces samonapędzający, umożliwiający platformom dynamiczny wzrost (Evans, 2003; Śledziwska i Włoch, 2020; Gyódi, 2017).

Korzyści skali w tradycyjnej gospodarce występują po stronie podażowej, i polegają na tym, że koszt przeciętny maleje wraz ze wzrostem produkcji. W przypadku platform, korzyści skali występują zarówno po stronie podażowej (np. więcej ofert, mniejsze koszty), jak i po stronie popytowej (np. większa liczba użytkowników, większa wartość platformy). Co więcej, platformy mogą skalować się szybciej i taniej niż firmy tradycyjne, ze względu na wyjątkowo niskie koszty jednostkowe obsługi danych, które wciąż się zmniejszają wraz z rozwojem technologii, a także relatywnie niskie zatrudnienie (OECD, 2019). Bowiem choć w przypadku platform, tak jak w przypadku firm tradycyjnych występują koszty stałe (wynajęcie przestrzeni roboczej, zakup sprzętu itd.), to zwiększenie liczby obsługiwanych klientów odbywać się może później przy bardzo niskich lub nawet prawie zerowych kosztach krańcowych (Śledziwska i Włoch, 2020).

Kolejnym mechanizmem dającym przewagę platformom jest występowanie w tradycyjnej gospodarce kosztów transakcyjnych, które w przypadku platform redukowane są niemal do zera. Wynika to z tego, że istotą ich działalności jest łączenie różnych stron rynku, co eliminuje potrzebę poszukiwania partnerów biznesowych (Parker, Van Alstyne i Choudary, 2016).

W rezultacie platformy funkcjonują jako systemy łączące strony rynku, w których efekty sieciowe, redukcja kosztów transakcyjnych oraz niskie koszty krańcowe prowadzą do wysokiej skalowalności i dynamicznego wzrostu.

1.3.4. Uber jako platforma

Jednym z głównych przykładów platform jest Uber. Analizuje go m.in. Gyódi (2017). W artykule, zgodnie z definicją przedstawioną wcześniej (patrz 1.3.2.), Uber ujęty jest jako platforma, pośrednik, którego jedyną rolą jest dostarczenie infrastruktury i umożliwienie dwóm stronom rynku – kierowcom i pasażerom – połączenia. Jako mechanizmy umożliwiające Uberowi dynamiczny rozwój przedstawione są efekty sieci (im więcej kierowców, tym atrakcyjniejsza aplikacja dla pasażerów i na odwrót), redukcja kosztów transakcyjnych (łatwość wyszukiwania, pewność transakcji, dopasowanie) oraz efekty skali (jako że Uber dostarcza jedynie infrastrukturę informatyczną, może rozszerzać swoją

działalność przy kosztach krańcowych bliskich zeru) (Gyódi, 2017). Jest to w pełni zgodne z platformową definicją przytaczaną wcześniej (patrz 1.3.3.).

1.3.5. Wpływ Ubera na sektor taxi

Wpływ platform takich jak Uber na sektor tradycyjnych taksówek oraz porównania obydwu sektorów prowadzone były nie tylko na poziomie teoretycznym, ale również empirycznym. Rayle et al. (2016) wskazują, na podstawie badania ankietowego przeprowadzonego w San Francisco, że floty *for-hire* zastępują zarówno tradycyjne taksówki, jak i transport publiczny (choć dla transportu publicznego pełnią również funkcję komplementarną). Głównymi przewagami tych flot nad tradycyjnymi taksówkami, które wskazywali ankietowani w artykule, była szybkość, a szczególnie krótszy czas oczekiwania (autorzy wykazali, że jest on niższy dla *fhv* w porównaniu do taxi niezależnie od strefy), a także wygoda, w tym m.in. możliwość uiszczenia opłaty przez aplikację. Cramer i Krueger (2016), wykorzystując dane z raportów TLC, innych prac badawczych oraz dostarczone przez Ubera, wykazali, że Uber ma ogólnie wyższy wskaźnik wykorzystania (ang. *utilization rate*) niż tradycyjne taksówki (co sugerowało, że kierowcy Ubera mogliby wykonywać tę samą pracę co kierowcy taxi w sposób bardziej efektywny). Wykazali oni także, że różnica między przewoźnikami była najmniejsza w Nowym Jorku. Według autorów mogło to być spowodowane przez wyjątkowo wysoką gęstość zamieszkania, dzięki której mechanizm łapania klientów na ulicy, stosowany przez tradycyjne taksówki, miał być skuteczniejszy. Tę teorię wspierają wnioski Nie (2017), który analizując sytuację w Shenzhen w Chinach wykazał, że taxi skuteczniej konkuruje z *fhv* w obszarach gęściej zaludnionych oraz w godzinach szczytu. Wnioski Cramera i Kruegera (2016) zostały doprecyzowane przez Lee et al. (2018), którzy wskazali, że odnoszą się one w istocie jedynie do Manhattanu, jako że to tam jest zlokalizowanych ponad 90% taxi. Lee et al. (2018) wykazali także, że wpływ popularności Ubera na taxi zależy od regionu i statusu ekonomicznego.

1.4. Hedoniczne modele cen

Przed przystąpieniem do omówienia badań empirycznych dotyczących Ubera, konieczne jest omówienie koncepcji cen hedonicznych. Opiera się ona na założeniu, że dobra nie są wartością samą w sobie (nie stanowią bezpośredniego źródła użyteczności), ale są zbiorem charakterystyk, i dopiero te charakterystyki dostarczają bezpośrednią wartość

(użyteczność) konsumentowi. W konsekwencji ceny dóbr wynikają właśnie z tych charakterystyk, z uwzględnieniem tego, że cena sama w sobie również ma wpływ na użyteczność konsumenta (Lancaster, 1966; Rosen, 1974). W literaturze transportowej wskazuje się, że w przypadku transportu kluczowymi wartościami mającymi bezpośredni wpływ na użyteczność konsumenta są m.in. cena, czas podróży, niezawodność czy jakość, zaś pośrednio (poprzez wpływ na czas, korki itd.) również dystans czy pora dnia (Small i Verhoef, 2007). Jednym z fundamentów w literaturze transportowej jest koncepcja „wartości czasu” (ang. *Value of Time*, *VOT*). Pojęcie to odnosi się do wartości przypisywanej przez jednostkę czasowi. *VOT* interpretować można zatem jako gotowość do zapłaty za skrócenie czasu podróży. W kontekście transportu oznacza to, że czas spędzony w podróży stanowi dla konsumenta koszt, który – podobnie jak koszt pieniężny – wpływa na jego decyzje oraz postrzeganą wartość usługi. Co więcej, różne formy czasu podróży (np. w korku vs. w ruchu płynnym) mogą być wyceniane przez konsumenta w różny sposób. To z kolei może sugerować, że wpływ czasu podróży i dystansu na cenę przejazdu nie musi być proporcjonalny (Abrantes i Wardman, 2011; Small, 2012).

Jak zatem widać, w przypadku Ubera i taxi uzasadnione jest zastosowanie modelu, w którym cena jest determinowana przez cechy przejazdu, zaś w przypadku determinant takich jak czas trwania przejazdu czy dystans uzasadnione jest uwzględnienie potencjalnych nieliniowości.

1.5. Determinanty cen przejazdów Ubera – badania empiryczne

Według analizy źródeł przedstawionej wcześniej (patrz 1.2.3. „Algorytm cenowy”), cena Ubera określana jest przez niejawną algorytm, który bierze pod uwagę m.in. dystans i czas przejazdu, warunki drogowe oraz podaż i popyt. Przed omówieniem prac skupiających się na analizie determinant cen, warto zwrócić uwagę na segment literatury analizujący je pośrednio, a mianowicie badający determinanty liczby przejazdów, jako że jest ona istotnym czynnikiem algorytmu cenowego. Badania te często skupiają się na wpływie pogody, która z kolei może być dobrym przybliżeniem dla okresów zwiększonego popytu, ponieważ podczas złej pogody, np. deszczu, popyt na środki transportu naturalnie wzrasta, jako że alternatywne formy transportu, takie jak chodzenie czy jazda na rowerze, stają się dużo mniej atrakcyjne (Brodeur i Nield, 2018).

Wpływ poszczególnych determinant na liczbę przejazdów Ubera jest niejednoznaczny. W literaturze można znaleźć zarówno prace wskazujące na istnienie silnej, pozytywnej

korelacji między deszczem a liczbą przejazdów (Brodeur i Nield, 2018), jak i prace wykazujące brak zależności w przypadku deszczu, a zależność występującą w przypadku pory dnia, dnia tygodnia czy temperatury (Correa i Moyano, 2023; Willis i Tranos, 2020). Chociaż artykuły te nie modelowały bezpośrednio cen, dostarczają one istotnych informacji oraz mogą wskazać potencjalne kierunki dalszych badań, jako że cena jest, szczególnie w przypadku Ubera, bezpośrednią pochodną popytu (Gurley, 2014). Co więcej, autorzy często wskazują na relatywnie słabą jakość danych (Brodeur i Nield, 2018; Correa i Moyano, 2023).

Przechodzimy zatem do segmentu literatury dotyczącego bezpośrednio problemu badawczego analizowanego w tej pracy – a więc determinant cen przejazdów Ubera. Prace badające ten problem często opierają się na danych z API Ubera i używają zwykle narzędzi takich jak statystyka opisowa i modele regresji. Analizowane są różne determinanty, a wśród nich dystans, pora dnia, weekendy, czas czy czas oczekiwania, a analiza przeprowadzana jest w różnych lokalizacjach, m.in. w Madrycie (Rangel et al., 2022), Austin (Jiao, 2018) czy Bostonie (Huang, 2023).

Co do determinant analizowanych w tej pracy, to literatura jest zgodna co do pozytywnej zależności między dystansem a ceną (Rangel et al., 2022; Huang, 2023; Shokoohyar, 2020).

Podobnie, literatura wskazuje na istnienie dodatniej zależności między czasem trwania przejazdu a ceną Ubera, choć ze względu na potencjalną współliniowość z dystansem często w estymacji używa się tylko jednej z tych zmiennych (Rangel et al., 2022).

Większość badań jest także zgodna co do istnienia pozytywnej zależności między cenami Ubera a porannymi oraz wieczornymi godzinami szczytu (Battifarano i Qian, 2019; Chao, 2019; Jiao, 2018; Rangel et al., 2022). Wyjątek stanowi Huang (2023), który wykazał brak zależności między godziną a ceną przejazdu, jednak uwzględnił on w modelu *surge-multiplier* bezpośrednio (jako zmienną ciągłą), zatem sprzeczność jego wyników może być efektem innej specyfikacji. Warto ponadto zaznaczyć, że wykorzystane przez niego dane, w tym wspomniany *surge-multiplier*, pochodzą z publicznego zbioru na Kaggle, zatem ich jakość może być kwestionowana.

Literatura nie jest natomiast zgodna co do związku weekendów z cenami Ubera – występują tutaj zarówno prace wskazujące na związek pozytywny (Rangel et al., 2022), jak i negatywny (Chao, 2019; Shokoohyar, 2020).

Jak zatem widać, literatura dotycząca determinant cen przejazdów Ubera nie jest szczególnie rozbudowana, a uzyskiwane wyniki nie są jednoznaczne. Warto przy tym zauważyć, że większość badań koncentruje się na analizie pojedynczych platform, najczęściej

Ubera lub Ubera i Lyfta, natomiast porównania z tradycyjnymi taksówkami pojawiają się rzadziej i mają zazwyczaj charakter bardziej ogólny, nie odnosząc się bezpośrednio do różnic w mechanizmach kształtowania cen.

Co więcej, zgodnie z najlepszą wiedzą autora, w literaturze empirycznej potencjalne zależności nieliniowe rzadko są analizowane bezpośrednio poprzez specyfikacje nieliniowe (np. z wykorzystaniem potęg zmiennych), pomimo że zarówno teoria, jak i literatura, uzasadniają uwzględnienie ich w analizie. Przemawiające za tym argumenty opisane zostały wcześniej (patrz 1.4.). Zgodnie z nimi nieliniowe zależności mogą być spowodowane choćby przez mechanizm wartości czasu (patrz 1.4.) lub *surge-pricing*. W sytuacjach zwiększonego popytu względem podaży cena przejazdu może rosnąć w sposób dyskretny i nieproporcjonalny do zmiany podstawowych charakterystyk przejazdu. Oznacza to, że wpływ czasu i dystansu na cenę jest modulowany przez warunki rynkowe, co dodatkowo wzmacnia potencjalnie nieliniowy charakter tych zależności (Rangel et al., 2022; Castillo, 2025; Garg, 2022).

1.6. Hipotezy i pytania badawcze

1.6.1. Pytania badawcze

Celem tej pracy jest zidentyfikowanie, zbadanie oraz porównanie czynników determinujących opłaty za przejazdy Ubera i tradycyjnych żółtych taksówek, ze szczególnym naciskiem na pory dnia, weekendy oraz nieliniowe zależności od dystansu i czasu. Postawione zostały wobec tego następujące pytania badawcze:

- Jakie czynniki wpływają na ceny przejazdów Ubera i tradycyjnych taksówek?
- Czy występują nieliniowe zależności między czasem lub dystansem a ceną w przypadku Ubera lub taxi?
- W jaki sposób wpływ poszczególnych czynników różni się między przewoźnikami?

Dla części z tych pytań można sformułować, na podstawie teorii oraz literatury, hipotezy dotyczące spodziewanych wyników.

1.6.2. Hipotezy badawcze

Zgodnie z podejściem hedonicznym (patrz 1.4.), cena przejazdu może być traktowana jako funkcja jego podstawowych charakterystyk, takich jak czas trwania oraz dystans. W

przypadku usług transportowych obie te zmienne stanowią kluczowe determinanty kosztu realizacji przejazdu, a tym samym jego ceny.

W przypadku tradycyjnych żółtych taksówek zależność ta wynika bezpośrednio z konstrukcji taryfy, zgodnie z którą opłata rośnie wraz z przejechanym dystansem oraz czasem trwania kursu (patrz 1.1.2.). W przypadku Ubera, pomimo niejawnego charakteru algorytmu cenowego, zarówno oficjalne informacje, jak i wyniki badań empirycznych wskazują na analogiczną, dodatnią zależność między tymi zmiennymi a ceną przejazdu (patrz 1.2.3., 1.5.).

Hipoteza 1. Istnieje dodatnia zależność między ceną przejazdu a dystansem w przypadku Ubera, jak i tradycyjnych taksówek.

Hipoteza 2. Istnieje dodatnia zależność między ceną przejazdu a czasem zarówno w przypadku Ubera, jak i tradycyjnych taksówek.

Dwie kolejne hipotezy odnoszą się do godzin szczytu, których występowanie wynika z charakterystycznego rytmu aktywności w obszarach miejskich. Rytm ten charakteryzuje większość tych obszarów i ma względnie stałą strukturę. W dni robocze w godzinach porannych następuje koncentracja popytu na transport, związana z rozpoczęciem dnia pracy oraz innych regularnych aktywności, co prowadzi do zwiększonego zapotrzebowania na usługi przewozowe. Podobna sytuacja następuje w godzinach wieczornych, ze względu na zakończenie dnia pracy i konieczność powrotów do miejsc zamieszkania.

Hipoteza 3. Istnieje zależność między porannymi godzinami szczytu w dni robocze a ceną przejazdów zarówno Ubera, jak i tradycyjnych taksówek. Założenie to wynika właśnie z miejskiego rytmu dnia. Dynamiczny wzrost popytu na przejazdy może prowadzić do wzrostu cen, ponieważ algorytm cenowy Ubera reaguje na popyt nadwyżkowy. Tę hipotezę wspierają Rangel et al. (2022), Chao (2019) oraz Battifarano i Qian (2019).

Hipoteza 4. Istnieje zależność między wieczornymi godzinami szczytu w dni robocze a ceną przejazdów zarówno Ubera, jak i tradycyjnych taksówek. Podstawą tej hipotezy jest, podobnie jak w przypadku godzin porannych, schemat miejskiego rytmu dnia. Warto jednak zauważyć, że siła tej zależności może być w tym przypadku inna, jako że presja poranna może być wyższa ze względu na konieczność dotarcia do pracy czy innych obowiązków. Hipotezę tę wspierają, zarówno na poziomie wpływu, jak i różnicy w sile wpływu w porównaniu z godzinami porannymi, Rangel et al. (2022), Chao (2019) oraz Battifarano i Qian (2019).

Hipoteza 5. Wpływ porannych godzin szczytu na ceny przejazdów jest silniejszy w przypadku Ubera niż w przypadku tradycyjnych taksówek. Biorąc pod uwagę, że aspekt popytowy kształtuje ceny Ubera w znacznie większym stopniu niż ceny tradycyjnych

taksówek (bo tradycyjne są ustalane taryfą, a Ubera dynamicznie), spodziewać się można, że wpływ porannych godzin szczytu na ceny przejazdów będzie silniejszy w przypadku Ubera niż w przypadku tradycyjnych taksówek. Hipotezę tę wspierają pośrednio wyniki uzyskane przez Brodeura i Nielda (2018), którzy wykazali, że wpływ pogody na liczbę przejazdów jest dużo silniejszy w przypadku Ubera i Lyfta niż w przypadku taxi.

Hipoteza 6. Zachodzą nieliniowe zależności między czasem i dystansem a ceną przejazdów Ubera. W przypadku tych nieliniowych zależności zarówno teoria, jak i literatura, uzasadniają uwzględnienie ich w analizie. Jak wspomniano wcześniej, nieliniowe zależności mogą być spowodowane choćby przez mechanizm wartości czasu lub *surge-pricing* (patrz 1.4., 1.5.). Mimo to, o czym również wspomniano wcześniej, zgodnie z najlepszą wiedzą autora, w literaturze empirycznej zależności te rzadko są analizowane bezpośrednio poprzez specyfikacje nieliniowe (np. z wykorzystaniem potęg zmiennych) (patrz 1.5.). Tym niemniej, przedstawione mechanizmy teoretyczne uzasadniają ich uwzględnienie w analizie.

ROZDZIAŁ II

Analiza empiryczna

2.1. Opis bazy danych

Dane pochodzą z comiesięcznych raportów NYC Taxi and Limousine Commission, dostępnych na stronie¹. Dokumenty te zawierają dane na poziomie mikro – jeden wiersz reprezentuje jeden przejazd – dotyczące przejazdów realizowanych w Nowym Jorku. Raporty dla różnych klasyfikacji pojazdów publikowane są w osobnych plikach – w tej pracy wykorzystane zostały te dotyczące tradycyjnych żółtych taksówek (*Yellow Taxi Trip Records*) oraz platform (patrz 1.2.1.) (*High Volume For-Hire Vehicle Trip Records*). Między tymi kategoriami raportowane pozycje różnią się częściowo nazewnictwem oraz typem – dokładne spisy raportowanych pozycji wraz z opisem dostępne są na stronach².

W tej pracy wykorzystane zostały raporty za styczeń, luty oraz marzec 2025. Okres ten stanowi cały kwartał i powinien dostarczyć wystarczającego horyzontu czasowego do zbadania postawionych hipotez i pytań badawczych. Każdy z raportów został indywidualnie wyczyszczony. Na potrzeby analizy z raportów platformowych uwzględniony został jedynie Uber (w raportach występował również Lyft), dlatego w dalszej części będą one określane jako „raporty Ubera”. Ze względu na to, że większość żółtych taksówek działa na Manhattanie, a także aby uniknąć konieczności uwzględniania w analizie kwestii lokalizacyjnych, które mogłyby generować heteroskedastyczność, a których analiza nie jest celem tej pracy, zbiór został dalej zawężony do przejazdów, których zarówno początek, jak i koniec miał miejsce na Manhattanie. W kolejnych krokach usunięte zostały rekordy będące ewidentnie błędne, np. zawierające wartości niedodatnie w polach takich jak dystans, czas czy opłaty. Usunięte zostały także rekordy niezgodne z przepisami, tj. mające wartości opłat dodatkowych niezgodne z ustalonymi stawkami (patrz 1.1.2.). Następnie, na podstawie pozycji raportowanych bezpośrednio w raportach stworzone zostały zmienne potrzebne do dalszej analizy, takie jak czas przejazdu (obliczony jako różnica między godziną zakończenia przejazdu (ang. *drop-off date*) a godziną rozpoczęcia przejazdu (ang. *pick-up date*)). Później usunięte zostały pozycje zbędne w dalszej analizie. Następnie nazwy zmiennych zostały ujednolicone między raportami taxi i Ubera. Później, w celu ułatwienia przeprowadzenia

¹<https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>

²https://www.nyc.gov/assets/tlc/downloads/pdf/data_dictionary_trip_records_yellow.pdf
https://www.nyc.gov/assets/tlc/downloads/pdf/data_dictionary_trip_records_hvfhs.pdf

analizy eksploracyjnej oraz stworzenia modelu ekonometrycznego, wszystkie pliki zostały połączone w jeden, zawierający zmienne takie jak dystans (*distance*), czas w minutach (*trip_time_mins*), opłata całkowita (*total_amount*) czy godzina (*hour*). Na koniec, po analizie wstępnej, ze względu na występowanie obserwacji teoretycznie poprawnych, jednak nie mających sensu z perspektywy praktycznej (np. dystans przejazdu 1000 mil), dane zostały ograniczone na podstawie górnych (0.99) i dolnych (0.01) kwantyli ze względu na dystans, czas w minutach, opłatę podstawową oraz opłatę całkowitą. Dzięki temu wyeliminowane zostały tego typu odchylenia, a także w znaczącym stopniu zredukowana została skośność i kurtoza rozkładów zmiennych. W wyniku tego ograniczenia usuniętych zostało 883 152 obserwacji, co stanowi 4,86% wszystkich obserwacji z wyczyszczonej bazy.

Baza danych ostatecznie użyta w analizie składa się z 17 304 478 obserwacji (10 382 174 dla Ubera i 6 922 304 dla żółtych taksówek. Obserwacje te obejmują okres od początku stycznia 2025 (pierwsza obserwacja 01.01.2025) do końca marca 2025 (ostatnia obserwacja 31.03.2025).

Końcowy zbiór zmiennych wykorzystanych w analizie przedstawiony został w Tabeli 2. Lista świąt federalnych dostępna jest na stronie https://www.ca2.uscourts.gov/clerk/calendars/federal_holidays.html, zaś pory dnia zostały ustalone na podstawie literatury (patrz 1.5., 1.6.2.) oraz analizy eksploracyjnej (patrz 2.2.).

Tabela 2. Opis zmiennych wykorzystanych w analizie

Nazwa zmiennej	Opis zmiennej	Typ zmiennej	Jednostka
total_amount	Końcowa cena przejazdu zapłacona przez pasażera; dla Ubera suma: <i>base_passenger_fare</i> , <i>tolls</i> , <i>bef</i> , <i>sales_tax</i> , <i>congestion_surcharge</i> , <i>cbd_congestion_fee</i> ; dla taxi suma: <i>fare_amount</i> , <i>extra</i> , <i>mta_tax</i> , <i>tolls_amount</i> , <i>improvement_surcharge</i> , <i>congestion_surcharge</i> , <i>cbd_congestion_fee</i>	ciągła	USD
distance	Dystans przejazdu; jedna z podstawowych determinant ceny zgodnie z teorią cen hedonicznych	ciągła	mile
trip_time_mins	Czas przejazdu; jedna z podstawowych determinant ceny zgodnie z teorią cen hedonicznych	ciągła	minuty
hour_gr 7-9	Poranne godziny szczytu	zero-jedynkowa	–

hour_gr 6, 9-17	Godziny o względnie stałym, niższym natężeniu ruchu (grupa bazowa)	zero-jedynkowa	—
hour_gr 17-21	Wieczne „pracowe” godziny szczytu	zero-jedynkowa	—
hour_gr 21-23	Godziny poprzedzające aktywności nocne	zero-jedynkowa	—
hour_gr 23-6	Godziny nocne	zero-jedynkowa	—
czy_weekend	Zmienna wskazująca weekend	zero-jedynkowa	—
month2	Luty; zmienna kontrolna sezonowości (baza: styczeń)	zero-jedynkowa	—
month3	Marzec; zmienna kontrolna sezonowości (baza: styczeń)	zero-jedynkowa	—
czy_01_01	Nowy Rok; zmienna kontrolna	zero-jedynkowa	—
czy_19_01	Święto federalne (Martin Luther King Jr. Day); zmienna kontrolna	zero-jedynkowa	—
czy_16_02	Święto federalne (Washington’s Birthday); zmienna kontrolna	zero-jedynkowa	—

Źródło: Opracowanie własne na podstawie danych zebranych z raportów NYC TLC

2.2. Analiza eksploracyjna

Tabela 3. przedstawia statystyki opisowe dla tradycyjnych żółtych taksówek, natomiast Tabela 4. dla Ubera.

Tabela 3. Statystyki opisowe dla tradycyjnych żółtych taksówek

Statystyka Zmienna	n	mean	sd	median	min	max	range	skew	kurtosis	se
distance	6922304	1.83	1.26	1.48	0.35	8.91	8.56	1.89	4.55	0
trip_time_mins	6922304	11.89	6.38	10.55	2.50	36.35	33.85	0.98	0.67	0
total_amount	6922304	21.08	7.27	19.38	9.40	71.41	62.01	1.19	1.59	0

Źródło: Opracowanie własne na podstawie danych zebranych z raportów NYC TLC


Tabela 4. Statystyki opisowe dla Ubera

Statystyka Zmienna	n	mean	sd	median	min	max	range	skew	kurtosis	se
distance	10382174	2.34	1.65	1.81	0.35	8.91	8.56	1.55	2.13	0
trip_time_mins	10382174	13.80	6.66	12.58	2.50	36.35	33.85	0.78	0.17	0
total_amount	10382174	27.59	12.06	25.06	9.40	71.43	62.03	0.98	0.67	0

Źródło: Opracowanie własne na podstawie danych zebranych z raportów NYC TLC


Jak widać w Tabelach 3. i 4., średnia, odchylenie standardowe oraz mediana są wyższe w próbie Ubera, a skośność i kurtoza są większe w próbie taxi. Natomiast minimum, maksimum i rozstęp są praktycznie takie same, co wynika z ograniczenia danych po kwantylach (patrz 2.1.). Szczególną uwagę zwrócić warto na fakt, iż ceny są średnio wyższe w przypadku Ubera niż w przypadku taxi. Na Rys 1. zobaczyć można rozkłady dystansu w postaci histogramu. Na Rys. 2. przedstawiony jest czas, zaś na Rys. 3. ceny. Histogramy te potwierdzają wnioski, jakie można wyciągnąć z Tabel 3. i 4. Szczególnie warto zwrócić uwagę na widoczną skośność prawostronną, a także na większy rozrzut wartości w przypadku Ubera.

Rys. 1. Histogramy dystansu dla taxi i Ubera




Źródło: Opracowanie własne na podstawie danych zebranych z raportów NYC TLC

Rys. 2. Histogramy czasu dla taxi i Ubera



Źródło: Opracowanie własne na podstawie danych zebranych z raportów NYC TLC


Rys. 3. Histogramy ceny dla taxi i Ubera



Źródło: Opracowanie własne na podstawie danych zebranych z raportów NYC TLC

Na Rys. 4. przedstawione są wykresy rozproszenia dystansu, czasu oraz ceny w podziale na taxi i Ubera.

Rys. 4. Wykresy rozproszenia dla taxi i Ubera



Źródło: Opracowanie własne na podstawie danych zebranych z raportów NYC TLC

Jak widać, w przypadku taxi zależność ceny zarówno od dystansu, jak i od czasu, jest dość skupiona i przyjmuje formę około liniową. Natomiast w przypadku Ubera rozrzut jest znacznie większy i nie widać na pierwszy rzut oka konkretnej formy zależności. Jest to zgodne z intuicją oraz przedstawionymi wcześniej hipotezami, gdyż wpływ dystansu i czasu na cenę przejazdu jest ściśle określony w przypadku taxi (patrz 1.1.2.), zaś w przypadku Ubera nie (patrz 1.2.3.). Jeśli chodzi o zależność między czasem a dystansem, to tutaj zarówno w przypadku taxi jak i Ubera zaobserwować można duży rozrzut, co może wynikać choćby z warunków drogowych.

W celu wzmocnienia oraz uzupełnienia wniosków płynących z Rys. 4., obliczona została macierz korelacji między dystansem, czasem oraz ceną. W celu jej wyznaczenia zastosowana została metoda Spearmana, jako że analizowane zmienne nie mają rozkładu normalnego. Macierz dla taxi widoczna jest w Tabeli 5., a dla Ubera w Tabeli 6. Obie potwierdzają silne dodatnie korelacje między wszystkimi trzema zmiennymi, zarówno w przypadku taxi jak i Ubera.

Tabela 5. Macierz korelacji dla dystansu, czasu i ceny dla taxi

	distance	trip_time_mins	total_amount
distance	1.000***	0.801***	0.852***

	distance	trip_time_mins	total_amount
trip_time_mins	0.801***	1.000***	0.909***
total_amount	0.852***	0.909***	1.000***

Źródło: Opracowanie własne na podstawie danych zebranych z raportów NYC TLC


Tabela 6. Macierz korelacji dla dystansu, czasu i ceny dla Ubera

	distance	trip_time_mins	total_amount
distance	1.000***	0.804***	0.659***
trip_time_mins	0.804***	1.000***	0.717***
total_amount	0.659***	0.717***	1.000***

Źródło: Opracowanie własne na podstawie danych zebranych z raportów NYC TLC

Warto jednak przy tym zauważyć, że korelacje dystansu z ceną oraz czasu z ceną są widocznie wyższe w przypadku taxi niż w przypadku Ubera. Obserwacja ta jest wzmocnieniem dla wniosków wyciągniętych wcześniej na podstawie Rys. 4.


Rys. 5. Rozkład liczby przejazdów dla taxi i Ubera w podziale na godzinę i dzień tygodnia



Źródło: Opracowanie własne na podstawie danych zebranych z raportów NYC TLC

Rys. 5. przedstawia rozkład liczby przejazdów w dniach i godzinach dla taxi i Ubera. W obu przypadkach zauważyć można pewne trendy, w większości podobne dla obu przewoźników. Tymi wspólnymi trendami są wzrosty natężenia liczby przejazdów w wieczornych godzinach szczytu w dni robocze. Wzmoczona aktywność występuje również w weekendy w godzinach nocnych. Istotną różnicę można zobaczyć w porannych godzinach szczytu w dni robocze. W przypadku taxi brak jest specyficznego wzrostu aktywności, a w zamian za to po prostu rozpoczyna się zwykłe natężenie, utrzymujące się również w godzinach późniejszych. W przypadku Ubera natomiast widoczny jest specyficzny okres wzmożonej aktywności w porannych godzinach szczytu, która następnie zmniejsza się w ciągu dnia. W ogólności zaobserwowany rozkład natężenia przejazdów jest zgodny z przedstawionym wcześniej modelem rytmu życia miasta (patrz 1.6.2.), a także z literaturą (patrz Battifarano i Qian, 2019). Warto zwrócić szczególną uwagę na większą zmienność liczby przejazdów Ubera w porównaniu z taxi, przejawiającą się choćby we wspomnianych porannych godzinach szczytu. Może ona sugerować większą elastyczność w podaży Ubera, przy bardziej sztywnej podaży tradycyjnych taksówek.

Rys. 6. Rozkład cen dla taxi i Ubera w podziale na godzinę i dzień tygodnia



Źródło: Opracowanie własne na podstawie danych zebranych z raportów NYC TLC

Na Rys. 6. przedstawiony został rozkład cen dla taxi i Ubera. Jak widać, w rozkładzie cen dla taxi występują stałe i relatywnie dobrze widoczne podziały, co po raz kolejny podtrzymuje argument o określoności cen taxi przez regulacje. Z drugiej strony, w przypadku Ubera brak jest widocznego schematu, co również wspiera wnioski przedstawione wcześniej, zgodnie z którymi cena Ubera kształtuje się dynamicznie, a zatem nie trzyma się jednego schematu.

2.3. Model ekonometryczny

2.3.1. Specyfikacja

W celu osiągnięcia celu pracy, odpowiedzi na pytania badawcze oraz zweryfikowania hipotez badawczych, zbudowany został model ekonometryczny. Specyfikacja oraz forma modelu wynikają bezpośrednio z literatury oraz analizy eksploracyjnej.

Modele dla taxi oraz Ubera zostały oszacowane oddzielnie, jednak ich forma jest jednakowa, zatem przy omawianiu specyfikacji oba modele traktowane będą jak jeden.

Wzór 1. Postać modelu bazowego

$$\ln(\text{total_amount}) = \text{distance} + \text{trip_time_mins} + \text{hour_gr} + \text{czy_weekend} + \text{hour_gr:czy_weekend} + \text{month} + \text{czy_01_01} + \text{czy_19_01} + \text{czy_16_02}$$

Postać modelu bazowego przedstawia Wzór 1. Zmienną objaśnianą jest zlogarytmowana opłata całkowita (*total_amount*) w dolarach. Forma zlogarytmowana została zastosowana ze względu na skośność rozkładów, gdyż zmniejsza ona wpływ wartości skrajnych, a także pozwala na interpretację parametrów jako semi-elastyczności, czyli jako przybliżone zmiany procentowe. W modelu bazowym zmiennymi objaśniającymi są: dystans, czas, pora dnia, weekend, interakcja weekendu z porą dnia, miesiąc oraz święta.

Wzór 2. Postać modelu rozszerzonego

$$\ln(\text{total_amount}) = \text{distance} + \text{trip_time_mins} + \text{distance}^2 + \text{trip_time_mins}^2 + \text{distance:trip_time_mins} + \text{hour_gr} + \text{czy_weekend} + \text{hour_gr:czy_weekend} + \text{month} + \text{czy_01_01} + \text{czy_19_01} + \text{czy_16_02}$$

Jako że wpływ dystansu i czasu nie musi być liniowy, co zostało przedstawione wcześniej, model bazowy został rozszerzony. W modelu rozszerzonym zachowane zostały wszystkie zmienne z modelu bazowego, a dodatkowo wprowadzone zostały następujące zmienne: dystans do kwadratu, czas do kwadratu oraz interakcja dystansu i czasu. Postać modelu rozszerzonego przedstawia Wzór 2. Uzupełnienie w ten sposób modelu bazowego umożliwia uchwycenie potencjalnych nieliniowości oraz współzależności między dystansem i czasem.

2.3.2. Diagnostyka

Zarówno dla modelu bazowego, jak i modelu rozszerzonego, przeprowadzona została diagnostyka w celu określenia właściwości modeli.

Testem RESET została zbadana liniowość formy funkcyjnej. Zarówno w modelu bazowym, jak i rozszerzonym na zadanym poziomie istotności należało odrzucić hipotezę zerową, a więc założenie o liniowości formy funkcyjnej zostało odrzucone. Podjęte zostały próby rozszerzenia modelu, zarówno pod kątem formy (lin-lin, log-log) jak i dodania kolejnych interakcji i potęg zmiennych, jednak nie poprawiły one istotnie jakości modelu, a dodatkowo znacznie komplikowały interpretację. Warto jednak zwrócić uwagę na fakt, że próba, której dotyczy analiza jest ogromna, zaś test RESET jest testem czułym na wielkość próby (Christodoulou-Volos i Tserkezos, 2026). Co więcej, celem tej pracy jest określenie kierunków zależności między analizowanymi determinantami cen przejazdów a ceną przejazdu, a cel ten może zostać osiągnięty pomimo obciążenia estymatorów wynikającego z nieliniowości formy funkcyjnej. Zatem modele wybrane ostatecznie do analizy, choć nie spełniają założenia o liniowości formy funkcyjnej, umożliwiają osiągnięcie celu pracy poprzez testowanie zależności przy względnie prostej interpretacji wyników.

Testem Breuscha – Pagana zbadana została homoskedastyczność reszt. Ponownie, hipoteza zerowa w obu modelach została odrzucona, co oznacza, że występuje heteroskedastyczność. W celu rozwiązania tego problemu zastosowane zostały klasyczne macierze odporne White'a (typ HC0). Ich zastosowanie nie wpłynęło jednak na wyniki wnioskowania – wszystkie zmienne pozostały statystycznie istotne na zadanym poziomie istotności.

Testem Jarque – Bera zbadana została normalność reszt. Jak poprzednio, hipoteza zerowa została odrzucona, zatem założenie o normalności reszt nie zostało utrzymane.

Jednak, biorąc pod uwagę wielkość próby, nie jest to problematyczne, gdyż zachowane są rozkłady asymptotyczne.

Sprawdzona została również współliniowość, jako że zgodnie z Tabelami 3. i 4. korelacja między zmiennymi była wysoka. W tym celu policzone zostały statystyki VIF, jednak we wszystkich przypadkach okazały się one mniejsze od 5, co sugeruje, że aspekt współliniowości nie stanowi problemu w analizowanych modelach.

2.3.3. Wyniki estymacji

Tabela 7. przedstawia wyniki estymacji, zarówno dla modelu bazowego, jak i rozszerzonego.

Tabela 7. Wyniki estymacji modeli ekonometrycznych

	<i>Dependent variable:</i>			
	I(log(total_amount))			
	Uber bazowy	Uber rozszerzony	Taxi rozszerzony	Taxi bazowy
distance	0.045*** (0.0001)	0.093*** (0.0003)	0.148*** (0.0001)	0.093*** (0.0001)
trip_time_mins	0.037*** (0.00002)	0.064*** (0.0001)	0.050*** (0.00003)	0.032*** (0.00001)
I(distance2)		-0.010*** (0.00004)	0.002*** (0.00002)	
I(trip_time_mins2)		-0.001*** (0.00000)	-0.0004*** (0.00000)	
hour_gr17-21	0.055*** (0.0003)	0.048*** (0.0003)	0.107*** (0.0001)	0.110*** (0.0001)
hour_gr21-23	0.115*** (0.0004)	0.104*** (0.0004)	0.050*** (0.0002)	0.057*** (0.0002)
hour_gr23-6	0.055*** (0.0004)	0.049*** (0.0004)	0.049*** (0.0002)	0.057*** (0.0002)
hour_gr7-9	0.025*** (0.0004)	0.022*** (0.0004)	-0.017*** (0.0002)	-0.015*** (0.0002)

czy_weekend	-0.024*** (0.0003)	-0.031*** (0.0003)	-0.021*** (0.0001)	-0.019*** (0.0001)
month2	0.014*** (0.0002)	0.015*** (0.0002)	0.001*** (0.0001)	0.001*** (0.0001)
month3	0.093*** (0.0002)	0.094*** (0.0002)	0.004*** (0.0001)	0.004*** (0.0001)
czy_01_01	0.033*** (0.001)	0.032*** (0.001)	-0.067*** (0.0004)	-0.066*** (0.0005)
czy_19_01	0.038*** (0.001)	0.037*** (0.001)	0.002*** (0.0004)	0.003*** (0.0005)
czy_16_02	-0.057*** (0.001)	-0.058*** (0.001)	0.003*** (0.0004)	0.004*** (0.0005)
distance:trip_time_mins		0.002*** (0.00002)	-0.004*** (0.00001)	
hour_gr17- 21:czy_weekend	-0.025*** (0.001)	-0.015*** (0.0005)	-0.096*** (0.0002)	-0.098*** (0.0002)
hour_gr21- 23:czy_weekend	-0.074*** (0.001)	-0.063*** (0.001)	0.012*** (0.0003)	0.008*** (0.0003)
hour_gr23- 6:czy_weekend	0.099*** (0.001)	0.106*** (0.001)	0.015*** (0.0003)	0.014*** (0.0003)
hour_gr7- 9:czy_weekend	-0.051*** (0.001)	-0.044*** (0.001)	0.016*** (0.0005)	0.016*** (0.001)
Constant	2.548*** (0.0003)	2.323*** (0.0005)	2.263*** (0.0002)	2.418*** (0.0001)
Observations	10,382,174	10,382,174	6,922,304	6,922,304
R ²	0.520	0.540	0.905	0.883
Adjusted R ²	0.520	0.540	0.905	0.883
Residual Std. Error	0.296 (df = 10382157)	0.289 (df = 10382154)	0.099 (df = 6922284)	0.110 (df = 6922287)
F Statistic	702,461.200* ** (df = 16;	641,511.400*** f = 19; 10382154)	(d 3,485,841.000*** (df = 19;	3,252,278.000* ** (df = 16;

10382157)

6922284)

6922287)

Note:

*p<0.1; **p<0.05; ***p<0.01

Źródło: Opracowanie własne na podstawie danych zebranych z raportów NYC TLC

Jako że zastosowany został model w formie log-liniowej, oszacowania parametrów traktować należy jako semi-elastyczności. Oznacza to, że zmiana x_1 o jednostkę powoduje, *ceteris paribus* (o ile ma to sens, bo np. w przypadku interakcji czy kwadratów nie ma sensu interpretacja oddzielna), wzrost wartości oczekiwanej y o $(\exp(\beta_1) - 1) \cdot 100\%$, a w przybliżeniu (dla małych β) o $\beta \cdot 100\%$. Czyli np. wzrost dystansu o jedną milę w modelu bazowym dla Ubera powoduje wzrost wartości oczekiwanej ceny o $(\exp(0,045) - 1) \cdot 100\% \approx 4,6\%$, czyli w przybliżeniu $0,045 \cdot 100\% = 4,5\%$. Poziom istotności został ustalony na poziomie 0,05, zarówno w modelach bazowych jak i rozszerzonych, i w obu przypadkach wszystkie zmienne okazały się statystycznie istotne. Wpływ każdego parametru z osobna analizowany jest przy założeniu *ceteris paribus*, czyli trzymając pozostałe zmienne stałe.

W pierwszej kolejności warto zwrócić uwagę na dopasowanie modeli. Model bazowy uzyskał R^2 na poziomie 0,52 w przypadku Ubera oraz 0,883 w przypadku taxi, natomiast w modelu rozszerzonym wartości te wynoszą odpowiednio 0,54 oraz 0,905. Oznacza to, że w przypadku Ubera modele wyjaśniają 52% oraz 54% zmienności ceny, podczas gdy dla taxi jest to aż 88,3% i 90,5%. Różnica między przewoźnikami jest zatem bardzo wyraźna i może wskazywać na odmienne mechanizmy kształtowania cen. W przypadku tradycyjnych taksówek wysoki poziom dopasowania wynika najprawdopodobniej z faktu, że ceny są w dużej mierze determinowane przez sztywną taryfę, której główne komponenty zostały uwzględnione w modelu. W przypadku Ubera natomiast niższe dopasowanie sugeruje większą zmienność cen oraz istotniejszą rolę czynników nieobserwowalnych, takich jak np. dynamiczne dostosowanie cen do bieżących warunków popytu i podaży poprzez *surge-pricing*. Tak więc już na tym początkowym etapie analizy widoczne jest, że ceny przejazdów taxi mają charakter bardziej przewidywalny i deterministyczny, podczas gdy ceny Ubera są bardziej elastyczne i zależne od sytuacji rynkowej.

W modelu bazowym zarówno dla Ubera, jak i dla taxi, wpływ dystansu na cenę przejazdu jest dodatni. W przypadku Ubera wzrost dystansu o jedną milę powoduje wzrost wartości oczekiwanej ceny o około 4,5%, natomiast dla taxi efekt ten jest wyraźnie większy i wynosi około 9,3%. Sugeruje to, że cena przejazdu jest silniej powiązana z dystansem w przypadku taxi niż w przypadku Ubera, co jest zgodne z wcześniejszymi wnioskami wynikającymi z analizy eksploracyjnej oraz opisu systemu taryfowego.

Wpływ czasu na cenę przejazdu również jest dodatni. Dla Ubera wzrost czasu o jedną minutę prowadzi do wzrostu ceny o około 3,7%, natomiast w przypadku taxi efekt ten wynosi około 3,2%. Warto zauważyć, że różnice między przewoźnikami są tym razem małe, co sugeruje, że czas przejazdu odgrywa bardziej zbliżoną rolę w kształtowaniu ceny w obu systemach. Jednocześnie należy zauważyć, że wpływ czasu jest niższy niż wpływ dystansu zarówno dla taxi jak i dla Ubera. Jest to zgodne z konstrukcją taryf oraz algorytmów, w których komponent dystansowy ma zwykle charakter podstawowy, a komponent czasowy pełni rolę uzupełniającą, szczególnie w warunkach niskiej prędkości lub postoju.

Wyniki dotyczące dystansu i czasu przejazdu uzyskane w modelu bazowym są zgodne z oczekiwaniami oraz hipotezami – obie zmienne są istotnymi determinantami ceny przejazdu zarówno Ubera, jak i taxi, a ich wpływ jest dodatni.

Ciekawych wniosków dostarcza analiza wpływu pór dnia oraz weekendu na ceny. Warto zwrócić tu szczególną uwagę na dwa aspekty – różnice między przewoźnikami w tych samych okresach oraz zmienność cen dla każdego z nich.

W przypadku taxi najsilniejszy wzrost cen obserwowany jest w klasycznych wieczornych godzinach szczytu 17-21 w dni robocze, gdzie ceny są wyższe o ok. 11% względem poziomu bazowego (dla przypomnienia, poziom bazowy został ustalony jako godziny (6, 9-17)). Efekt ten jest zgodny z przewidywaniami i wynika najprawdopodobniej z konstrukcji taryfy, zgodnie z którą w tym przedziale czasowym obowiązuje dodatkowa opłata (*rush hour surcharge*). Ceny Ubera także reagują na ten okres, jednak wzrost jest tam znacznie mniejszy (ok. 5,5%). Warto zauważyć, że zarówno w przypadku taxi, jak i Ubera, efekt zanika w weekendy, co wspiera hipotezę o „pracowych” wieczornych godzinach szczytu w dni robocze.

W przypadku godzin 21-23 oraz 23-6 efekt dla taxi jest względnie stały, zarówno w dni robocze, jak i w weekendy (ok. 4,5-5,5%). Jest to zgodne z konstrukcją taryfy, która przewiduje stałą opłatę nocną we wszystkie dni tygodnia. Sytuacja jest odmienna w przypadku Ubera. Tutaj efekt godzin 21-23 jest znacznie większy w dni robocze (ok. 11,5%), a w weekendy praktycznie zanika (ok. 1,7%). Natomiast efekt godzin nocnych jest największy w weekendy (ok. 13%), zaś w dni robocze jest zbliżony do poziomu taxi (ok. 5,5%). Oznacza to, że Uber cechuje się dużo większą zmiennością w godzinach wieczornych i nocnych, podczas gdy taxi reaguje silniej na klasyczne „pracowe” wieczorne godziny szczytu. Jest to zgodne z oczekiwaniami wynikającymi z konstrukcji taryfy dla taxi oraz działania mechanizmu cenowego Ubera.

Efekty porannych godzin szczytu 7-9 są stosunkowo słabe dla obu przewoźników. Warto jednak odnotować, że w przypadku Ubera w weekend występuje efekt ujemny (ok. -5%), który w połączeniu z dodatnim wynikiem dni roboczych (2,5%) sugeruje, że ceny Ubera w porannych godzinach szczytu w dni robocze są o ok. 7,5% wyższe niż w tym samym okresie w weekend. Wynik ten wspiera hipotezy o dodatnim wpływie porannych godzin szczytu oraz większej elastyczności Ubera.

Jak zatem widać, poszczególne pory dnia wpływają w różny sposób na poszczególnych przewoźników. Co więcej, wpływ ten różni się także między dniami roboczymi w weekendem. Nie sposób zatem określić jednoznacznie wpływu weekendu na ceny. Warto natomiast zauważyć, że ceny Ubera cechują się znacznie większą zmiennością pomiędzy dniami roboczymi a weekendami niż ceny taxi, które dla wszystkich pór dnia z wyjątkiem godzin 17-21 zachowują się praktycznie tak samo w dni robocze i weekendy.

Efekty miesięcy oraz świąt również wspierają hipotezę o większej zmienności cen Ubera przy bardziej stabilnych cenach taxi.

Model rozszerzony zawiera, oprócz wszystkich zmiennych z modelu bazowego, trzy dodatkowe zmienne – dystans w kwadracie, czas w kwadracie oraz interakcję czasu z dystansem. Wprowadzenie tych zmiennych uzasadnione zostało w poprzednich sekcjach. Wnioski odnoszące się do wpływu pór dnia, weekendu, miesięcy oraz świąt pozostały, z uwzględnieniem drobnych zmian wartości, naturalnych przy wprowadzeniu dodatkowych zmiennych, takie same jak w modelu bazowym, zatem nie będą tu ponownie omawiane. Wprowadzenie zmiennych dodatkowych umożliwia natomiast analizę czasu oraz dystansu pod kątem potencjalnych nieliniowości we wpływach krańcowych, a wzrost skorygowanego R^2 w porównaniu z modelem bazowym po ich wprowadzeniu potwierdza tego wprowadzenia zasadność.

Jeśli chodzi o wpływ dystansu, to w modelu rozszerzonym wzrost jego wartości o milę powoduje, *ceteris paribus*, wzrost wartości oczekiwanej ceny o $(9,3 - 2*1*dystans + 0,2*czas)[\%]$ dla Ubera oraz $(14,8 + 2*0,2*dystans - 0,4*czas)[\%]$ dla taxi. Jak zatem widać, w modelu rozszerzonym wpływ dystansu na cenę nie jest stały, lecz zmienia się wraz z poziomem dystansu (a przy uchyleniu założenia *ceteris paribus*, także czasu). Warto zauważyć, że w przypadku Ubera, ze względu na ujemny parametr przy zmiennej dystans do kwadratu, wpływ dystansu maleje wraz z jego wzrostem. Oznacza to, że każda kolejna mila wpływa na cenę w coraz mniejszym stopniu. W przypadku taxi sytuacja jest natomiast odwrotna. Dodatni parametr przy dystansie do kwadratu oznacza, że wpływ dystansu rośnie

wraz z jego wzrostem, czyli każda kolejna mila zwiększa cenę w coraz większym stopniu, przy danym poziomie czasu.

W analogiczny sposób można przeanalizować wpływ czasu na cenę w modelu rozszerzonym. Krańcowy wpływ czasu, podobnie jak w przypadku dystansu, nie jest stały, lecz zależy od poziomu czasu (oraz, przy uchyleniu założenia *ceteris paribus*, dystansu). Dla Ubera wzrost czasu przejazdu o jedną minutę powoduje, *ceteris paribus*, wzrost wartości oczekiwanej ceny o $(6,4 - 2 \cdot 0,1 \cdot \text{czas} + 0,2 \cdot \text{dystans})[\%]$, natomiast dla taxi $(3,2 - 2 \cdot 0,04 \cdot \text{czas} - 0,4 \cdot \text{dystans})[\%]$. Warto zauważyć, że w przypadku czasu znak parametru przy czasie do kwadratu jest ujemny dla obu przewoźników. Oznacza to, że wpływ czasu maleje wraz z jego wzrostem zarówno dla Ubera, jak i dla taxi. Zatem, dla obu przewoźników każda kolejna minuta wpływa na cenę w coraz mniejszym stopniu.

Szczególną uwagę warto zwrócić na interakcje czasu z dystansem. W przypadku Ubera jej znak jest dodatni, co może sugerować, że algorytm cenowy uwzględnia dodatkowy koszt w sytuacjach takich jak korki, co jest zgodne z *surge-pricingiem*. W przypadku taxi interakcja jest natomiast ujemna, co wskazuje na występowanie substytucji między dystansem a czasem, np. w warunkach dużego natężenia ruchu wpływ dystansu na cenę jest mniejszy. Mechanizmy te wydają się spójne z konstrukcją taryfy taxi i algorytmu cenowego Ubera.

2.4. Weryfikacja hipotez badawczych

Na podstawie przeprowadzonej analizy możliwe jest zweryfikowanie postawionych pytań i hipotez badawczych. Uzyskane wyniki potwierdzają występowanie zależności między poszczególnymi cechami przejazdów – czasem, dystansem, porą dnia i weekendem – a cenami przejazdów zarówno w przypadku Ubera, jak i taxi. Pozytywnie zweryfikowane zostało również występowanie różnic między przewoźnikami, a także występowanie zależności nieliniowych między czasem i dystansem a ceną.

Oszacowanie modelu ekonometrycznego pozwala na bardziej dokładną analizę zależności, do których odnosiły się pytania badawcze, a do których zostały sformułowane również hipotezy.

Wyniki wspierają pierwszą hipotezę, zgodnie z którą zależność między ceną przejazdu a czasem jego trwania jest dodatnia zarówno w przypadku Ubera jak i taxi.

Podobnie pozytywnie zweryfikowana została hipoteza druga, stanowiąca że zależność między ceną przejazdu a dystansem jest dodatnia zarówno w przypadku Ubera jak i taxi.

Analiza potwierdziła również zasadność hipotezy trzeciej, mówiącej o istnieniu zależności pomiędzy porannymi godzinami szczytu w dni robocze a ceną Ubera i taxi. Warto jednak zauważyć, że efekt tego okresu jest niewielki w przypadku obu przewoźników oraz że kierunek zależności jest w przypadku Ubera dodatni, zaś w przypadku taxi ujemny. Co więcej, podczas gdy dla taxi weekend jest bez większego znaczenia, to dla Ubera efekt weekendowych porannych godzin szczytu jest dużo silniejszy (choć w przeciwną stronę) niż w dni robocze.

Na podstawie wyników pozytywnie zweryfikowana została również hipoteza czwarta – o istnieniu zależności między wieczornymi godzinami szczytu w dni robocze a ceną Ubera i taxi. Tutaj również jednak otrzymane wyniki są warte bliższego spojrzenia oraz porównania między dniami roboczymi a weekendem. W dni robocze dla taxi wieczorne godziny szczytu mają znaczny efekt dodatni, natomiast w weekendy efekt ten znika, a wynika to najprawdopodobniej z konstrukcji taryfy, gdzie w weekendy nie obowiązuje *rush hour surcharge*. W przypadku Ubera, choć kierunek zależności jest podobny, to wynika on zapewne z braku „pracowych” wieczornych godzin szczytu w weekendy.

Jak wspomniano wyżej, wpływ porannych godzin szczytu na ceny przejazdów okazał się silniejszy w przypadku Ubera niż w przypadku taxi. Tym samym pozytywnie została zweryfikowana hipoteza piąta, mówiąca o tym, że wpływ porannych godzin szczytu na ceny przejazdów jest silniejszy w przypadku Ubera niż w przypadku tradycyjnych taksówek właśnie. Różnica ta jest szczególnie widoczna w weekendy, a może wynikać ze stosowania *surge-pricingu* przez Ubera, podczas gdy taksówki są ograniczone taryfą.

Jak widać, wpływ weekendu, omówiony powyżej, nie jest jednoznaczny, ale zależy od pory dnia.

Jeśli chodzi o zależności nieliniowe wpływu czasu i dystansu, to na podstawie przeprowadzonej analizy można zawyrokować, że takowe występują, co wspiera hipotezę szóstą. W przypadku Ubera każda kolejna mila lub minuta zwiększa cenę w coraz mniejszym stopniu. Sugeruje to bardziej elastyczny i wygładzony mechanizm ustalania cen w porównaniu do tradycyjnych taksówek, dla których efekty kwadratowe czasu i dystansu są o rząd wielkości mniejsze niż dla Ubera. Co więcej, w przypadku Ubera interakcja między czasem a dystansem ma charakter dodatni, co wskazuje na komplementarność tych czynników i oznacza, że długie oraz czasochłonne przejazdy stają się nieproporcjonalnie drogie. Wynik ten jest zgodny z bardziej dynamicznym i elastycznym mechanizmem ustalania cen, charakterystycznym dla platform przewozowych wykorzystujących algorytmy typu *surge-pricing*. Z kolei w przypadku taxi interakcja czasu z dystansem ma charakter

ujemny, co oznacza, że czynniki te mają charakter substytucyjny. Odpowiada to logice tradycyjnej taryfy taxi, w której opłaty za czas i dystans częściowo się równoważą.

ZAKOŃCZENIE

Celem pracy była analiza czynników determinujących ceny przejazdów Ubera i tradycyjnych taksówek. Przeprowadzona została na podstawie raportów NYC TLC z wykorzystaniem metod statystycznych oraz modelu regresji liniowej estymowanego klasyczną metodą najmniejszych kwadratów.

Przeprowadzona analiza umożliwiła weryfikację postawionych hipotez oraz odpowiedzi na zadane pytania badawcze. Zgodnie z uzyskanymi wynikami można stwierdzić, że występują zależności między czasem przejazdu, dystansem przejazdu, porą dnia oraz weekendem a ceną przejazdu, zarówno w przypadku Ubera jak i tradycyjnych żółtych taksówek. Co więcej, zachodzą nieliniowe zależności między czasem i dystansem a cenami Ubera i taxi. Szczególnie ciekawym aspektem są różnice między przewoźnikami oraz wynikające z nich implikacje dla systemów ustalania cen, zwłaszcza w kontekście elastyczności, adaptacyjności i efektywności.

Wyniki uzyskane dzięki oszacowaniu modelu ekonometrycznego potwierdzają, że dystans i czas są podstawowymi determinantami cen. Jednakże, w przypadku Ubera każda kolejna mila lub minuta zwiększa cenę w coraz mniejszym stopniu, co sugeruje bardziej elastyczny i wygładzony mechanizm ustalania cen niż w przypadku taxi. Co więcej, w przypadku Ubera interakcja między czasem a dystansem ma charakter dodatni, co wskazuje na komplementarność tych czynników i oznacza, że długie oraz czasochłonne przejazdy stają się nieproporcjonalnie drogie. Wynik ten jest zgodny z bardziej dynamicznym i elastycznym mechanizmem ustalania cen, charakterystycznym dla platform przewozowych wykorzystujących algorytmy typu *surge-pricing*. Z kolei w przypadku taxi interakcja czasu z dystansem ma charakter ujemny, co oznacza, że czynniki te mają charakter substytucyjny. Odpowiada to logice tradycyjnej taryfy taxi, w której opłaty za czas i dystans częściowo się równoważą.

Większą elastyczność w mechanizmie cenowym Ubera w stosunku do taxi potwierdzają także różnice w zmienności cen przewoźników w zależności od pór dnia oraz weekendów. W przypadku taxi zmienność ta jest dużo mniejsza, co jest zgodne z mechanizmem taryfowym, w którym opłaty są określone z góry. W przypadku Ubera natomiast zaobserwować można większą zmienność cen, co odpowiada bardziej elastycznemu mechanizmowi, reagującemu na warunki rynkowe.

Przeprowadzona analiza dostarcza istotnych informacji na temat funkcjonowania Ubera i tradycyjnych żółtych taksówek, a w szczególności występujących między nimi podobieństw

i różnic. Najważniejszym wnioskiem jest potwierdzenie większej elastyczności mechanizmu cenowego Ubera w stosunku do taxi. Wnioski wyciągnięte z tej analizy mogą być bardzo przydatne dla wszystkich stron rynku przewozów taksówkowych. Pasażerowie mogą dzięki nim być w stanie dokonywać bardziej ekonomicznych wyborów dotyczących swoich podróży. Kierowcy mogą maksymalizować swoje zyski, choćby poprzez wykorzystanie okresów zwiększonego popytu. Przewoźnicy mogą efektywniej zarządzać podażą oraz popytem poprzez stosowanie odpowiednich polityk motywacyjnych dla kierowców i promocyjnych dla pasażerów. Politycy i decydenci mogą natomiast wykorzystać uzyskane wyniki do analizy efektywności użycia środków transportu publicznego oraz dalszych regulacji rynku.

W przeprowadzonej analizie występują również ograniczenia. Badanie obejmowało wyłącznie przejazdy realizowane na Manhattanie w pierwszym kwartale 2025 roku, co może ograniczać możliwość uogólniania wyników na inne lokalizacje oraz okresy czasu. Ponadto w analizie nie zostały uwzględnione wszystkie potencjalnie istotne determinanty cen – pominięte zostały choćby warunki pogodowe, natężenie ruchu czy wydarzenia specjalne, takie jak koncerty czy wiece.

Ograniczenia te warto byłoby zaadresować w kolejnych badaniach – przeprowadzić podobne analizy dla innych lokalizacji oraz dłuższych okresów czasu, a także uwzględnić dodatkowe zmienne opisujące warunki rynkowe i drogowe. Aspektem również wartym uwagi wydają się być nieliniowości wpływu czasu i dystansu na cenę przejazdu. Ich dalsze zbadanie także mogłoby dostarczyć ciekawych i przydatnych wniosków.

BIBLIOGRAFIA

- Abraham, K. G., Haltiwanger, J. C., Hou, C., Sandusky, K., & Spletzer, J. R. (2024). Driving the Gig Economy. *IZA Institute of Labor Economics*. <https://www.jstor.org/stable/resrep68969>
- Abrantes, P. A. L., & Wardman, M. R. (2011). Meta-analysis of UK values of travel time: An update. *Transportation Research Part A*, 45, 1–17. <https://doi.org/10.1016/j.tra.2010.08.003>
- Armstrong, M. (2006). Competition in two-sided markets. *RAND Journal of Economics*, 37, 668–691. <https://doi.org/10.1111/j.1756-2171.2006.tb00037.x>
- Battifarano, M., & Qian, Z. (Sean). (2019). Predicting real-time surge pricing of ride-sourcing companies. *Transportation Research Part C*, 107, 444–462. <https://doi.org/10.1016/j.trc.2019.08.019>
- Binns, R., Stein, J., Datta, S., Kleek, M. V., & Shadbolt, N. (2025). Not Even Nice Work If You Can Get It; A Longitudinal Study of Uber's Algorithmic Pay and Pricing. *Proceedings of the 2025 ACM Conference on Fairness, Accountability, and Transparency (FaccT 2025)* <https://doi.org/10.1145/3715275.3732099>
- Brodeur, A., & Nield, K. (2018). An empirical analysis of taxi, Lyft and Uber rides: Evidence from weather shocks in NYC. *Journal of Economic Behavior & Organization*, 152, 1–16. <https://doi.org/10.1016/j.jebo.2018.06.004>
- Castillo, J. C. (2025). Who Benefits from Surge Pricing?. *Econometrica*, 93, 1811-1854. <https://doi.org/10.3982/ECTA19106>
- Chao, J. (2019). Modeling and Analysis of Uber's Rider Pricing. *Proceedings of the 2019 International Conference on Economic Management and Cultural Industry (ICEMCI 2019)*. <https://doi.org/10.2991/aebmr.k.191217.127>
- Chen, L., Mislove, A., & Wilson, C. (2015). Peeking Beneath the Hood of Uber. *Proceedings of the 2015 Internet Measurement Conference*, 495–508. <https://doi.org/10.1145/2815675.2815681>
- Christodoulou-Volos, C., & Tserkezos, D. (2026). Time Aggregation and the RESET Test: Implications for Exchange Rate Modeling. *Theoretical and Practical Research in Economic Fields*, 17, 166-174. [https://doi.org/10.14505/tpref.v17.1\(37\).12](https://doi.org/10.14505/tpref.v17.1(37).12)
- Correa, D., & Moyano, C. (2023). Analysis and prediction of New York City taxi and Uber demands. *Journal of Applied Research and Technology*, 21, 886-898 <https://doi.org/10.22201/icat.24486736e.2023.21.5.2074>
- EBSCO. (2024). Uber (company). On line. Dostęp 13 maja 2026. <https://www.ebsco.com/research-starters/business-and-management/uber-company>

- Evans, D. S. (2003). The Antitrust Economics of Multi-Sided Platform Markets. *Yale Journal on Regulation*, 20, 325-381. <http://dx.doi.org/10.2139/ssrn.332022>
- Evans, D. S., & Schmalensee, R. (2016). *Matchmakers: The New Economics of Multisided Platforms*. Harvard Business Review Press. Boston.
- Garg, N., & Nazerzadeh, H. (2021). Driver Surge Pricing. *Management Science*, 68. [10.1287/mnsc.2021.4058](https://doi.org/10.1287/mnsc.2021.4058)
- Gurley, B. (2014). A deeper look at Uber's dynamic pricing model. Above the Crowd. On line. Dostęp 13 maja 2026. <https://abovethecrowd.com/2014/03/11/a-deeper-look-at-ubers-dynamic-pricing-model/>
- Gyódi, K. (2017). Uber vs licensed taxi drivers: A war between technological standards. Working Paper DELab UW | No. 2(2017). https://delab.uw.edu.pl/wp-content/uploads/2024/05/wp_2_2017_k.gyodi_.pdf
- Hall, J. V., & Krueger, A. B. (2016). An Analysis of the Labor Market for Uber's Driver-Partners in the United States. National Bureau of Economic Research Working Paper No. 22083. <http://www.nber.org/papers/w22083>
- Hall, J., Kendrick, C., & Nosko, C. (2015). The Effects of Uber's Surge Pricing: A Case Study. On line. Dostęp 13 maja 2026. https://andrewchen.com/wp-content/uploads/2016/01/effects_of_ubers_surge_pricing.pdf
- Huang, H. (2023). Ridesharing Price Prediction: Exploring the strategies of Dynamic Pricing. *Highlights in Business, Economics and Management*, 10, 106–110. <https://doi.org/10.54097/hbem.v10i.7963>
- Jiao, J. (2018). Investigating Uber price surges during a special event in Austin, TX. *Research in Transportation Business & Management*, 29, 101–107. <https://doi.org/10.1016/j.rtbm.2018.02.008>
- Lancaster, K. J. (1966). A New Approach to Consumer Theory. *Journal of Political Economy*, 74, 132-157. <http://www.jstor.com/stable/1828835>
- Lee, Y., Park, J., & Lee, B. (2018). Battle of Sharing Economy: The Contingent Effects of Ride-Sharing on Taxi Industry. *Proceedings of the 51st Hawaii International Conference on System Sciences*. <https://doi.org/10.24251/HICSS.2018.083>
- Meelen, T. & Koen F. (2015). Stop saying Uber is part of the sharing economy. On line. Dostęp 13 maja 2026. <https://www.fastcompany.com/3040863/stop-saying-uber-is-part-of-the-sharing-economy>
- Miasto Warszawa. (2026). Warszawskie Badanie Ruchu, czyli jak przemieszczają się mieszkańcy stolicy i metropolii?. On line. Dostęp 13 maja 2026. <https://um.warszawa.pl/-/warszawskie-badanie-ruchu-czyli-jak-przemieszczaja-sie-mieszkanczy-stolicy-i-metropolii->

- New York City Taxi and Limousine Commission. (b.d.). The early years: 1907–1935. On line. Dostęp 13 maja 2026. https://www.nyc.gov/html/media/totweb/taxioftomorrow_history_earlyyears.html
- New York City Taxi and Limousine Commission. (b.d.). Regulation and prosperity: 1935–1960. On line. Dostęp 13 maja 2026. https://www.nyc.gov/html/media/totweb/taxioftomorrow_history_regulationandprosperity.html
- New York City Taxi and Limousine Commission. (b.d.). The modern taxi: 1960–2010. On line. Dostęp 13 maja 2026. https://www.nyc.gov/html/media/totweb/taxioftomorrow_history_themoderntaxi.html
- New York City Taxi and Limousine Commission. (b.d.). About TLC. On line. Dostęp 13 maja 2026. <https://www.nyc.gov/site/tlc/about/about-tlc.page>
- New York City Taxi and Limousine Commission. (b.d.). For-Hire Vehicle Bases. On line. Dostęp 13 maja 2026. <https://www.nyc.gov/site/tlc/businesses/for-hire-vehicles.page>
- New York City Taxi and Limousine Commission. (b.d.). High-Volume For-Hire Services. On line. Dostęp 13 maja 2026. <https://www.nyc.gov/site/tlc/businesses/high-volume-for-hire-services.page>
- New York City Taxi and Limousine Commission. (b.d.). Your Ride. On line. Dostęp 13 maja 2026. <https://www.nyc.gov/site/tlc/passengers/your-ride.page>
- New York City Taxi and Limousine Commission. (b.d.). Reports. On line. Dostęp 13 maja 2026. <https://www.nyc.gov/site/tlc/about/industry-reports.page>
- New York City Taxi and Limousine Commission. (2025). 2025 Annual Report. On line. Dostęp 13 maja 2026. https://www.nyc.gov/assets/tlc/downloads/pdf/annual_report_2025.pdf
- New York City Taxi and Limousine Commission. (b.d.). Taxi Fare. On line. Dostęp 13 maja 2026. <https://www.nyc.gov/site/tlc/passengers/taxi-fare.page>
- Nie, Y. (Marco). (2017). How can the taxi industry survive the tide of ridesourcing? Evidence from Shenzhen, China. *Transportation Research Part C*, 79, 242–256. <https://doi.org/10.1016/j.trc.2017.03.017>
- OECD. (2019). *An Introduction to Online Platforms and Their Role in the Digital Transformation*. OECD Publishing, Paris. On line. Dostęp 13 maja 2026. <https://doi.org/10.1787/53e5f593-en>
- Pepić, L. (2018). The sharing economy: Uber and its effect on taxi companies. *ACTA ECONOMICA*, 16, 123-136. <https://doi.org/10.7251/ACE1828123P>
- Parker, G. G., Van Alstyne, M. W., & Choudary, S. P. (2016). *Platform Revolution. How Networked Markets Are Transforming the Economy And How to Make Them Work for You*. W.W. Norton & Company. New York.

- Rangel, T., Gonzalez, J. N., Gomez, J., Romero, F., & Vassallo, J. M. (2022). Exploring ride-hailing fares: An empirical analysis of the case of Madrid. *Transportation*, 49, 373–393. <https://doi.org/10.1007/s11116-021-10180-w>
- Rayle, L., Dai, D., Chan, N., Cervero, R., & Shaheen, S. (2016). Just a better taxi? A survey-based comparison of taxis, transit, and ridesourcing services in San Francisco. *Transport Policy*, 45, 168–178. <https://doi.org/10.1016/j.tranpol.2015.10.004>
- Rochet, J.-C., & Tirole, J. (2006). Two-sided markets: A progress report. *The RAND Journal of Economics*, 37, 645–667. <https://doi.org/10.1111/j.1756-2171.2006.tb00036.x>
- Rosen, S. (1974). Hedonic Prices and Implicit Markets: Product Differentiation in Pure Competition. *Journal of Political Economy*, 82, 34–55. <https://doi.org/10.1086/260169>
- Shokoohyar, S., Sobhani, A., & Sobhani, A. (2020). Impacts of trip characteristics and weather condition on ride-sourcing network: Evidence from Uber and Lyft. *Research in Transportation Economics*, 80. <https://doi.org/10.1016/j.retrec.2020.100820>
- Small, K. A. & Verhoef, E. T. (2007). *The Economics of Urban Transportation*. Routledge. <https://doi.org/10.4324/9781315157375>
- Small, K. A. (2012). Valuation of travel time. *Economics of Transportation*, 1, 2–14. <https://doi.org/10.1016/j.ecotra.2012.09.002>
- Śledziewska, K., & Włoch, R. (2020). *Gospodarka cyfrowa. Jak nowe technologie zmieniają świat?*. Wydawnictwa Uniwersytetu Warszawskiego, Warszawa 2020.
- Uber. (2018). What is Uber? Facts and information about Uber. On line. Dostęp 13 maja 2026. <https://www.uber.com/en-ZA/blog/what-is-uber-facts/>
- Uber. (2019). How dynamic pricing works. On line. Dostęp 13 maja 2026. <https://www.uber.com/en-GH/blog/uber-dynamic-pricing/>
- United States Court of Appeals for the Second Circuit. (b.d.). Federal holidays 2026. On line. Dostęp 13 maja 2026. https://www.ca2.uscourts.gov/clerk/calendars/federal_holidays.html
- Willis, G., & Tranos, E. (2020). Using 'Big Data' to understand the impacts of Uber on taxis in New York City. *Travel Behaviour and Society*, 22, 94–107. <https://doi.org/10.1016/j.tbs.2020.08.003>

ZESTAWIENIE SPISÓW

Wykaz skrótów

NYC	-	New York City
TLC	-	Taxi and Limousine Commission
HVFHS	-	High-Volume For-Hire Services
HVFHV	-	High-Volume For-Hire Vehicles
fhv	-	for-hire vehicles

Spis tabel

Tabela 1.	Składowe opłaty końcowej obliczanej na podstawie taryfy taxi NYC	9
Tabela 2.	Opis zmiennych wykorzystanych w analizie	22
Tabela 3.	Statystyki opisowe dla tradycyjnych żółtych taksówek.	23
Tabela 4.	Statystyki opisowe dla Ubera	23
Tabela 5.	Macierz korelacji dla dystansu, czasu i ceny dla taxi	26
Tabela 6.	Macierz korelacji dla dystansu, czasu i ceny dla Ubera	27
Tabela 7.	Wyniki estymacji modeli ekonometrycznych	31

Spis rysunków

Rys. 1.	Histogramy dystansu dla taxi i Ubera	24
Rys. 2.	Histogramy czasu dla taxi i Ubera	25
Rys. 3.	Histogramy ceny dla taxi i Ubera	25
Rys. 4.	Wykresy rozproszenia dla taxi i Ubera	26
Rys. 5.	Rozkład liczby przejazdów dla taxi i Ubera w podziale na godzinę i dzień tygodnia	27
Rys. 6.	Rozkład cen dla taxi i Ubera w podziale na godzinę i dzień tygodnia	28

Spis załączników

Załącznik 1. Wyniki testów statystycznych.....	47
--	----

ZAŁĄCZNIKI

Załącznik 1. Wyniki testów statystycznych

Test	Model	Uber bazowy	Uber rozszerzony	Taxi rozszerzony	Taxi bazowy
RESET		p-value < 2.2e-16 ***	p-value < 2.2e-16 ***	p-value < 2.2e-16 ***	p-value < 2.2e-16 ***
Test Breuscha - Pagana		p-value < 2.2e-16 ***	p-value < 2.2e-16 ***	p-value < 2.2e-16 ***	p-value < 2.2e-16 ***
Test Jarque – Bera		p-value < 2.2e-16 ***	p-value < 2.2e-16 ***	p-value < 2.2e-16 ***	p-value < 2.2e-16 ***